Обработка пропусков в данных, кодирование категориальных признаков, масштабирование данных.

Для данной лабораторной работы я использую набор данных индекса свободы человека по странам за 2018 год:

Контекст

Центральная цель Индекса свободы человека заключается в том, чтобы нарисовать широкую, но достаточно точную картину масштабов общей свободы в мире. Более широкая цель состоит в том, чтобы более тщательно изучить, что мы подразумеваем под свободой, и лучше понять ее связь с любым количеством других социально-экономических явлений.

Содержание

Индекс свободы человека измеряет экономические свободы, такие как свобода торговли или использования здоровых денег, и отражает степень, в которой люди свободны свободно пользоваться основными свободами, часто называемыми гражданскими свободами - свободой слова, религии, ассоциаций и собраний - в странах, участвующих в обзоре. Кроме того, он включает в себя показатели верховенства права, преступности и насилия, свободы передвижения и правовой дискриминации в отношении однополых отношений. Мы также включаем девять переменных, относящихся к свободам, специфичным для женщин, которые содержатся в различных категориях индекса.

Набор данных имеет следующие столбцы:

- year - год
- ISO_code - буквенное обозначение страны
- countries - страны
- region - регион
- pf_rol_procedural - процедурное правосудие
- pf_rol_civil - гражданская справедливость
- pf_rol_criminal - уголовное правосудие
- pf_rol - верховенство права
- pf_ss_homicide - убийству
- pf_ss_disappearances_disap - исчезновение
- ...

In [2]:
```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
```

```
%matplotlib inline
sns.set(style="ticks")
```

Первичный анализ данных

In [17]:
```
# читаем данные набора
data = pd.read_csv('JupyterNotebooks/data/hfi_cc_2018.csv', sep=",")
```

In [18]:
```
data.shape
```

Out[18]:
```
(1458, 123)
```

In [19]:
```
# типы данных столбцов
data.dtypes
```

Out[19]:
```
year                   int64
ISO_code              object
countries             object
region                object
pf_rol_procedural    float64
                       ...
ef_score             float64
ef_rank              float64
hf_score             float64
hf_rank              float64
hf_quartile          float64
Length: 123, dtype: object
```

In [21]:
```
# суммы пропусков по столбцам
data.isnull().sum()
```

Out[21]:
```
year                   0
ISO_code               0
countries              0
region                 0
pf_rol_procedural    578
                    ...
ef_score              80
ef_rank               80
hf_score              80
hf_rank               80
hf_quartile           80
Length: 123, dtype: int64
```

In [29]:
```
data.head()
```

Out[29]:

	year	ISO_code	countries	region	pf_rol_procedural	pf_rol_civil	pf_rol_criminal	
0	2016	ALB	Albania	Eastern Europe	6.661503	4.547244	4.666508	5.2
1	2016	DZA	Algeria	Middle East & North Africa	NaN	NaN	NaN	3.8
2	2016	AGO	Angola	Sub-Saharan Africa	NaN	NaN	NaN	3.4
3	2016	ARG	Argentina	Latin America & the Caribbean	7.098483	5.791960	4.343930	5.7
4	2016	ARM	Armenia	Caucasus	NaN	NaN	NaN	5.0

				& Central Asia			

5 rows × 123 columns

In [30]:
```
total_count = data.shape[0]
```

Обработка пропусков значений в наборе данных

Удалим те строки данных, в которых встречаются пустые столбцы:

In [22]:
```
# Удаление строк, содержащих пустые значения
data_new_2 = data.dropna(axis=0, how='any')
(data.shape, data_new_2.shape)
```

Out[22]:
```
((1458, 123), (0, 123))
```

Итоговая сетка данных оказывается пустой, так как в каждой строке так или иначе встечаются пропуски данных. В таком случае попробуем заполнить пустые значения например нулями.

In [26]:
```
# Заполнение всех пропущенных значений нулями
data_new_3 = data.fillna(0)
data_new_3.head()
```

Out[26]:

	year	ISO_code	countries	region	pf_rol_procedural	pf_rol_civil	pf_rol_criminal	
0	2016	ALB	Albania	Eastern Europe	6.661503	4.547244	4.666508	5.2
1	2016	DZA	Algeria	Middle East & North Africa	0.000000	0.000000	0.000000	3.8
2	2016	AGO	Angola	Sub-Saharan Africa	0.000000	0.000000	0.000000	3.4
3	2016	ARG	Argentina	Latin America & the Caribbean	7.098483	5.791960	4.343930	5.7
4	2016	ARM	Armenia	Caucasus & Central Asia	0.000000	0.000000	0.000000	5.0

5 rows × 123 columns

Это не очень корректно, так как и категориальные данных заполняются нулями.

Импьютация

Обработка числовых данных

In [31]:
```
# Выберем числовые колонки с пропущенными значениями
# Цикл по колонкам датасета
num_cols = []
for col in data.columns:
```

```
    # Количество пустых значений
    temp_null_count = data[data[col].isnull()].shape[0]
    dt = str(data[col].dtype)
    if temp_null_count>0 and (dt=='float64' or dt=='int64'):
        num_cols.append(col)
        temp_perc = round((temp_null_count / total_count) * 100.0, 2)
        print('Колонка {}. Тип данных {}. Количество пустых значений {},
```

```
Колонка pf_rol_procedural. Тип данных float64. Количество пустых значений
578, 39.64%.
Колонка pf_rol_civil. Тип данных float64. Количество пустых значений 578,
39.64%.
Колонка pf_rol_criminal. Тип данных float64. Количество пустых значений 5
78, 39.64%.
Колонка pf_rol. Тип данных float64. Количество пустых значений 80, 5.49%.
Колонка pf_ss_homicide. Тип данных float64. Количество пустых значений 8
0, 5.49%.
Колонка pf_ss_disappearances_disap. Тип данных float64. Количество пустых
значений 89, 6.1%.
Колонка pf_ss_disappearances_violent. Тип данных float64. Количество пуст
ых значений 80, 5.49%.
Колонка pf_ss_disappearances_organized. Тип данных float64. Количество пу
стых значений 179, 12.28%.
Колонка pf_ss_disappearances_fatalities. Тип данных float64. Количество п
устых значений 80, 5.49%.
Колонка pf_ss_disappearances_injuries. Тип данных float64. Количество пус
тых значений 80, 5.49%.
Колонка pf_ss_disappearances. Тип данных float64. Количество пустых значе
ний 80, 5.49%.
Колонка pf_ss_women_fgm. Тип данных float64. Количество пустых значений 1
72, 11.8%.
Колонка pf_ss_women_missing. Тип данных float64. Количество пустых значен
ий 120, 8.23%.
Колонка pf_ss_women_inheritance_widows. Тип данных float64. Количество пу
стых значений 541, 37.11%.
Колонка pf_ss_women_inheritance_daughters. Тип данных float64. Количество
пустых значений 541, 37.11%.
Колонка pf_ss_women_inheritance. Тип данных float64. Количество пустых зн
ачений 119, 8.16%.
Колонка pf_ss_women. Тип данных float64. Количество пустых значений 100,
6.86%.
Колонка pf_ss. Тип данных float64. Количество пустых значений 80, 5.49%.
Колонка pf_movement_domestic. Тип данных float64. Количество пустых значе
ний 98, 6.72%.
Колонка pf_movement_foreign. Тип данных float64. Количество пустых значен
ий 98, 6.72%.
Колонка pf_movement_women. Тип данных float64. Количество пустых значений
141, 9.67%.
Колонка pf_movement. Тип данных float64. Количество пустых значений 80,
5.49%.
Колонка pf_religion_estop_establish. Тип данных float64. Количество пусты
х значений 731, 50.14%.
Колонка pf_religion_estop_operate. Тип данных float64. Количество пустых
значений 731, 50.14%.
Колонка pf_religion_estop. Тип данных float64. Количество пустых значений
329, 22.57%.
Колонка pf_religion_harassment. Тип данных float64. Количество пустых зна
чений 94, 6.45%.
Колонка pf_religion_restrictions. Тип данных float64. Количество пустых з
начений 94, 6.45%.
Колонка pf_religion. Тип данных float64. Количество пустых значений 90,
6.17%.
Колонка pf_association_association. Тип данных float64. Количество пустых
значений 329, 22.57%.
Колонка pf_association_assembly. Тип данных float64. Количество пустых зн
ачений 329, 22.57%.
Колонка pf_association_political_establish. Тип данных float64. Количеств
о пустых значений 731, 50.14%.
```

Колонка pf_association_political_operate. Тип данных float64. Количество пустых значений 731, 50.14%.
Колонка pf_association_political. Тип данных float64. Количество пустых значений 329, 22.57%.
Колонка pf_association_prof_establish. Тип данных float64. Количество пустых значений 731, 50.14%.
Колонка pf_association_prof_operate. Тип данных float64. Количество пустых значений 731, 50.14%.
Колонка pf_association_prof. Тип данных float64. Количество пустых значений 329, 22.57%.
Колонка pf_association_sport_establish. Тип данных float64. Количество пустых значений 731, 50.14%.
Колонка pf_association_sport_operate. Тип данных float64. Количество пустых значений 731, 50.14%.
Колонка pf_association_sport. Тип данных float64. Количество пустых значений 329, 22.57%.
Колонка pf_association. Тип данных float64. Количество пустых значений 329, 22.57%.
Колонка pf_expression_killed. Тип данных float64. Количество пустых значений 80, 5.49%.
Колонка pf_expression_jailed. Тип данных float64. Количество пустых значений 80, 5.49%.
Колонка pf_expression_influence. Тип данных float64. Количество пустых значений 80, 5.49%.
Колонка pf_expression_control. Тип данных float64. Количество пустых значений 80, 5.49%.
Колонка pf_expression_cable. Тип данных float64. Количество пустых значений 335, 22.98%.
Колонка pf_expression_newspapers. Тип данных float64. Количество пустых значений 335, 22.98%.
Колонка pf_expression_internet. Тип данных float64. Количество пустых значений 329, 22.57%.
Колонка pf_expression. Тип данных float64. Количество пустых значений 80, 5.49%.
Колонка pf_identity_legal. Тип данных float64. Количество пустых значений 1253, 85.94%.
Колонка pf_identity_parental_marriage. Тип данных float64. Количество пустых значений 535, 36.69%.
Колонка pf_identity_parental_divorce. Тип данных float64. Количество пустых значений 535, 36.69%.
Колонка pf_identity_parental. Тип данных float64. Количество пустых значений 100, 6.86%.
Колонка pf_identity_sex_male. Тип данных float64. Количество пустых значений 83, 5.69%.
Колонка pf_identity_sex_female. Тип данных float64. Количество пустых значений 80, 5.49%.
Колонка pf_identity_sex. Тип данных float64. Количество пустых значений 80, 5.49%.
Колонка pf_identity_divorce. Тип данных float64. Количество пустых значений 873, 59.88%.
Колонка pf_identity. Тип данных float64. Количество пустых значений 80, 5.49%.
Колонка pf_score. Тип данных float64. Количество пустых значений 80, 5.49%.
Колонка pf_rank. Тип данных float64. Количество пустых значений 80, 5.49%.
Колонка ef_government_consumption. Тип данных float64. Количество пустых значений 66, 4.53%.
Колонка ef_government_transfers. Тип данных float64. Количество пустых значений 160, 10.97%.
Колонка ef_government_enterprises. Тип данных float64. Количество пустых значений 104, 7.13%.
Колонка ef_government_tax_income. Тип данных float64. Количество пустых значений 124, 8.5%.
Колонка ef_government_tax_payroll. Тип данных float64. Количество пустых значений 193, 13.24%.
Колонка ef_government_tax. Тип данных float64. Количество пустых значений 124, 8.5%.

Колонка ef_government. Тип данных float64. Количество пустых значений 80, 5.49%.
Колонка ef_legal_judicial. Тип данных float64. Количество пустых значений 167, 11.45%.
Колонка ef_legal_courts. Тип данных float64. Количество пустых значений 8 0, 5.49%.
Колонка ef_legal_protection. Тип данных float64. Количество пустых значен ий 169, 11.59%.
Колонка ef_legal_military. Тип данных float64. Количество пустых значений 80, 5.49%.
Колонка ef_legal_integrity. Тип данных float64. Количество пустых значени й 277, 19.0%.
Колонка ef_legal_enforcement. Тип данных float64. Количество пустых значе ний 90, 6.17%.
Колонка ef_legal_restrictions. Тип данных float64. Количество пустых знач ений 100, 6.86%.
Колонка ef_legal_police. Тип данных float64. Количество пустых значений 1 69, 11.59%.
Колонка ef_legal_crime. Тип данных float64. Количество пустых значений 16 9, 11.59%.
Колонка ef_legal_gender. Тип данных float64. Количество пустых значений 2 4, 1.65%.
Колонка ef_legal. Тип данных float64. Количество пустых значений 80, 5.4 9%.
Колонка ef_money_growth. Тип данных float64. Количество пустых значений 7 0, 4.8%.
Колонка ef_money_sd. Тип данных float64. Количество пустых значений 72, 4.94%.
Колонка ef_money_inflation. Тип данных float64. Количество пустых значени й 72, 4.94%.
Колонка ef_money_currency. Тип данных float64. Количество пустых значений 80, 5.49%.
Колонка ef_money. Тип данных float64. Количество пустых значений 82, 5.6 2%.
Колонка ef_trade_tariffs_revenue. Тип данных float64. Количество пустых з начений 169, 11.59%.
Колонка ef_trade_tariffs_mean. Тип данных float64. Количество пустых знач ений 92, 6.31%.
Колонка ef_trade_tariffs_sd. Тип данных float64. Количество пустых значен ий 91, 6.24%.
Колонка ef_trade_tariffs. Тип данных float64. Количество пустых значений 85, 5.83%.
Колонка ef_trade_regulatory_nontariff. Тип данных float64. Количество пус тых значений 170, 11.66%.
Колонка ef_trade_regulatory_compliance. Тип данных float64. Количество пу стых значений 90, 6.17%.
Колонка ef_trade_regulatory. Тип данных float64. Количество пустых значен ий 84, 5.76%.
Колонка ef_trade_black. Тип данных float64. Количество пустых значений 8 7, 5.97%.
Колонка ef_trade_movement_foreign. Тип данных float64. Количество пустых значений 164, 11.25%.
Колонка ef_trade_movement_capital. Тип данных float64. Количество пустых значений 89, 6.1%.
Колонка ef_trade_movement_visit. Тип данных float64. Количество пустых зн ачений 85, 5.83%.
Колонка ef_trade_movement. Тип данных float64. Количество пустых значений 80, 5.49%.
Колонка ef_trade. Тип данных float64. Количество пустых значений 81, 5.5 6%.
Колонка ef_regulation_credit_ownership. Тип данных float64. Количество пу стых значений 172, 11.8%.
Колонка ef_regulation_credit_private. Тип данных float64. Количество пуст ых значений 72, 4.94%.
Колонка ef_regulation_credit_interest. Тип данных float64. Количество пус тых значений 100, 6.86%.
Колонка ef_regulation_credit. Тип данных float64. Количество пустых значе ний 80, 5.49%.

```
Колонка ef_regulation_labor_minwage. Тип данных float64. Количество пусты
х значений 91, 6.24%.
Колонка ef_regulation_labor_firing. Тип данных float64. Количество пустых
значений 171, 11.73%.
Колонка ef_regulation_labor_bargain. Тип данных float64. Количество пусты
х значений 170, 11.66%.
Колонка ef_regulation_labor_hours. Тип данных float64. Количество пустых
значений 88, 6.04%.
Колонка ef_regulation_labor_dismissal. Тип данных float64. Количество пус
тых значений 110, 7.54%.
Колонка ef_regulation_labor_conscription. Тип данных float64. Количество
пустых значений 81, 5.56%.
Колонка ef_regulation_labor. Тип данных float64. Количество пустых значен
ий 84, 5.76%.
Колонка ef_regulation_business_adm. Тип данных float64. Количество пустых
значений 169, 11.59%.
Колонка ef_regulation_business_bureaucracy. Тип данных float64. Количеств
о пустых значений 102, 7.0%.
Колонка ef_regulation_business_start. Тип данных float64. Количество пуст
ых значений 90, 6.17%.
Колонка ef_regulation_business_bribes. Тип данных float64. Количество пус
тых значений 175, 12.0%.
Колонка ef_regulation_business_licensing. Тип данных float64. Количество
пустых значений 101, 6.93%.
Колонка ef_regulation_business_compliance. Тип данных float64. Количество
пустых значений 90, 6.17%.
Колонка ef_regulation_business. Тип данных float64. Количество пустых зна
чений 84, 5.76%.
Колонка ef_regulation. Тип данных float64. Количество пустых значений 80,
5.49%.
Колонка ef_score. Тип данных float64. Количество пустых значений 80, 5.4
9%.
Колонка ef_rank. Тип данных float64. Количество пустых значений 80, 5.4
9%.
Колонка hf_score. Тип данных float64. Количество пустых значений 80, 5.4
9%.
Колонка hf_rank. Тип данных float64. Количество пустых значений 80, 5.4
9%.
Колонка hf_quartile. Тип данных float64. Количество пустых значений 80,
5.49%.
```

In [32]:
```
# Фильтр по колонкам с пропущенными значениями
data_num = data[num_cols]
data_num
```

Out[32]:

	pf_rol_procedural	pf_rol_civil	pf_rol_criminal	pf_rol	pf_ss_homicide	pf_ss_disapp
0	6.661503	4.547244	4.666508	5.291752	8.920429	
1	NaN	NaN	NaN	3.819566	9.456254	
2	NaN	NaN	NaN	3.451814	8.060260	
3	7.098483	5.791960	4.343930	5.744791	7.622974	
4	NaN	NaN	NaN	5.003205	8.808750	
...	...	...	...	...	...	
1453	3.000000	3.781688	2.369239	3.100000	0.000000	
1454	6.666667	4.349101	5.694847	5.600000	9.496239	
1455	NaN	NaN	NaN	NaN	NaN	
1456	4.800000	4.578003	3.688652	4.400000	7.878084	
1457	2.700000	3.991582	4.327660	3.700000	7.981019	

1458 rows × 119 columns

119 колонок из 123 являются численными и имеют пропуски данных.

In [35]:
```
# Гистограмма по признакам
for col in data_num:
    plt.hist(data[col], 50)
    plt.xlabel(col)
    plt.show()
```

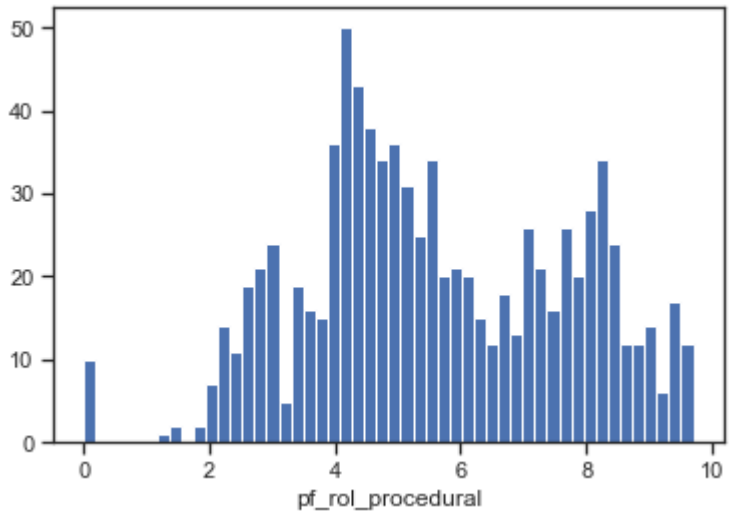

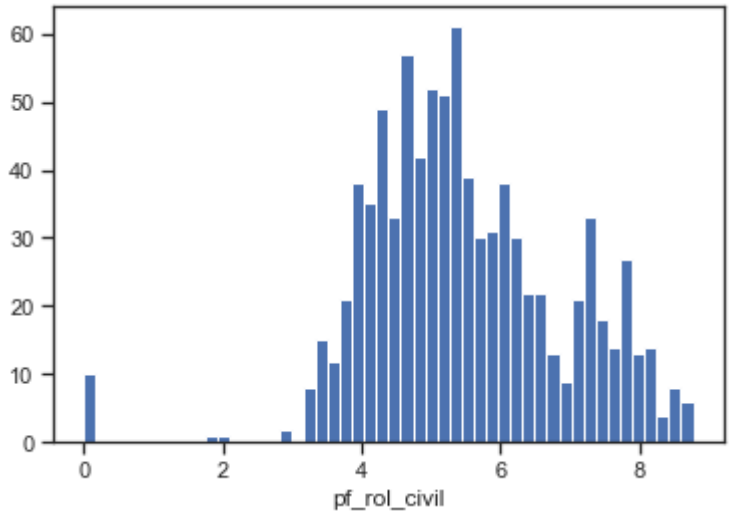

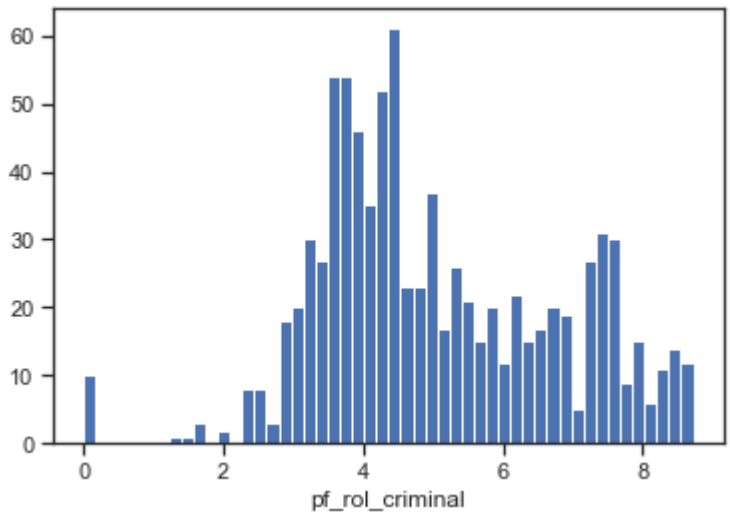

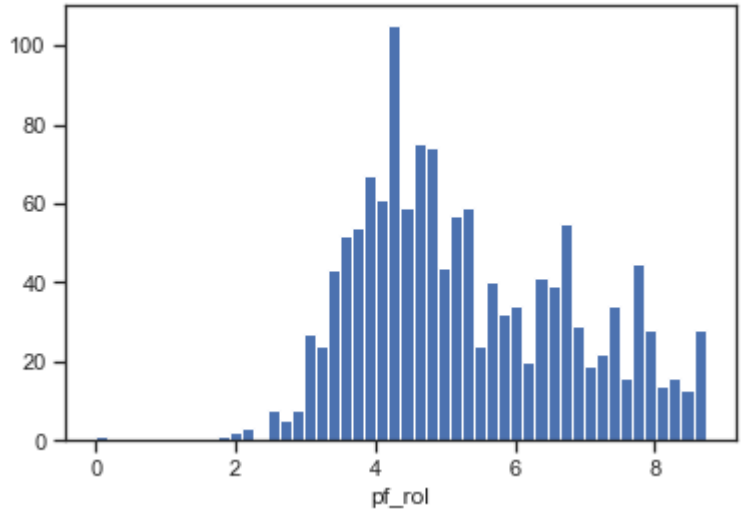
100
80
60
40
20
0
0
2
4
6
8
pf_rol

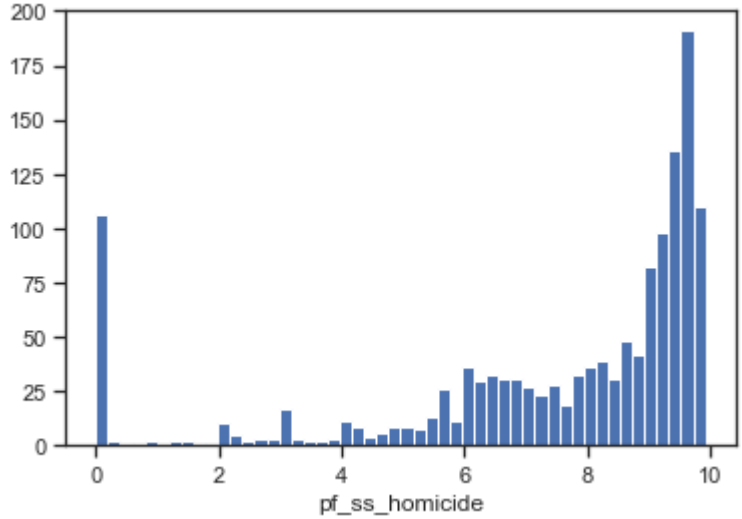
200
175
150
125
100
75
50
25
0
0
2
4
6
8
10
pf_ss_homicide

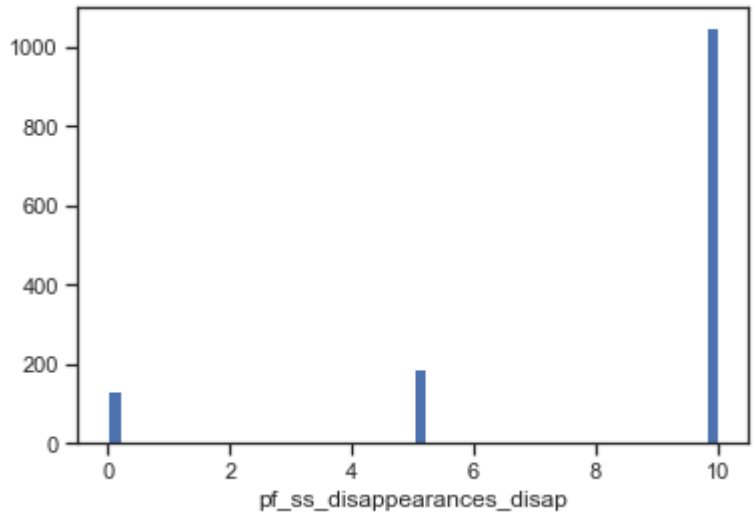
1000
800
600
400
200
0
0
2
4
6
8
10
pf_ss_disappearances_disap

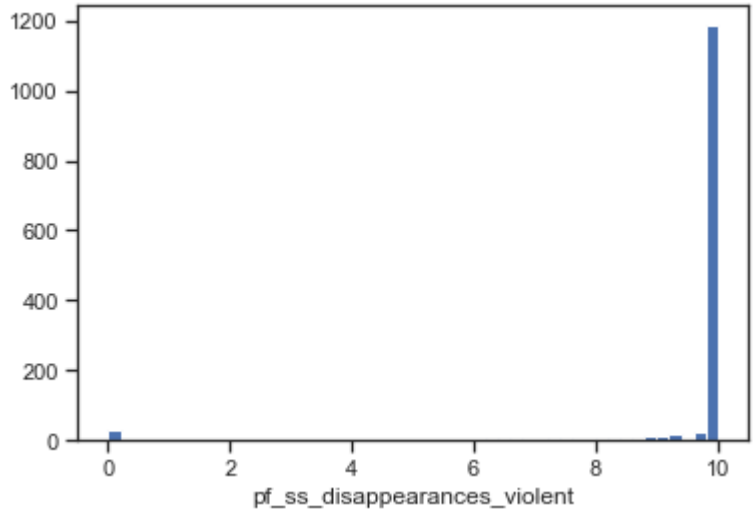
1200
1000
800
600
400
200
0
0
2
4
6
8
10
pf_ss_disappearances_violent

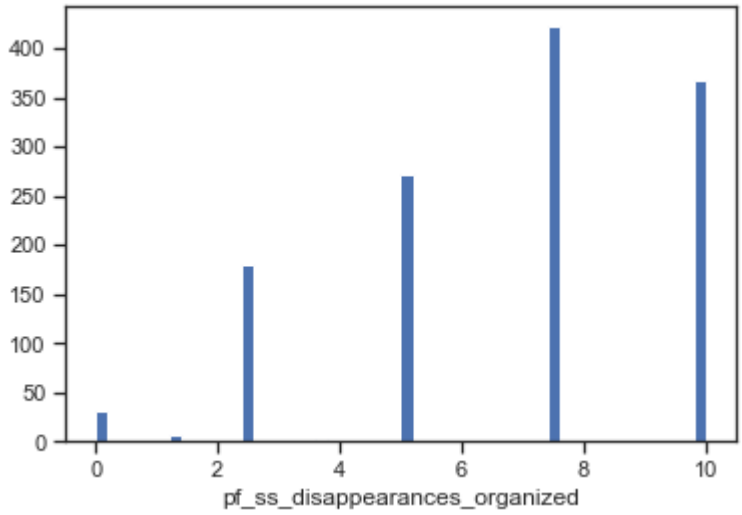
400
350
300
250
200
150
100
50
0
0
2
4
6
8
10
pf_ss_disappearances_organized

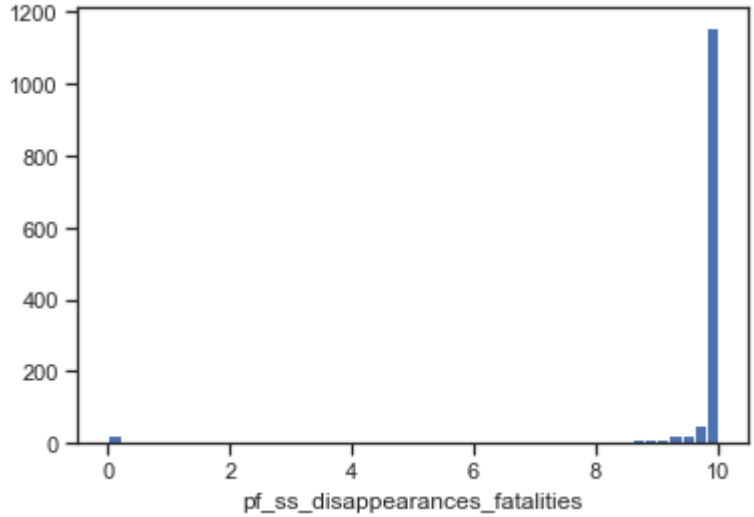
1200
1000
800
600
400
200
0
0
2
4
6
8
10
pf_ss_disappearances_fatalities

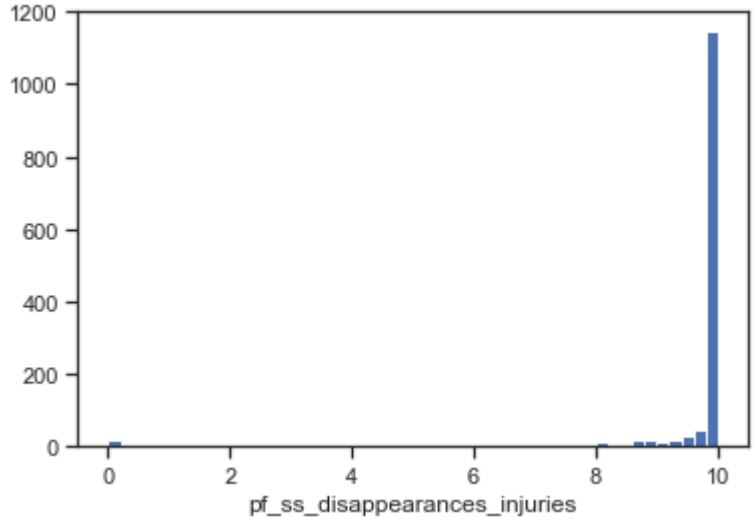
1200
1000
800
600
400
200
0
0
2
4
6
8
10
pf_ss_disappearances_injuries

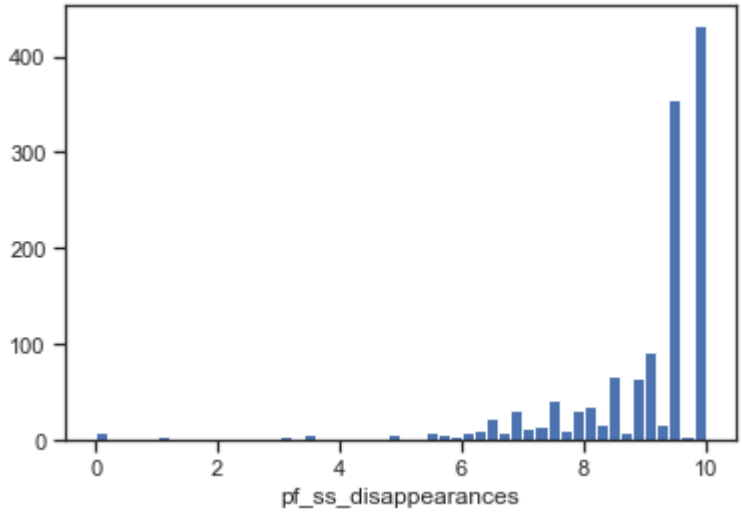
400
300
200
100
0
0
2
4
6
8
10
pf_ss_disappearances

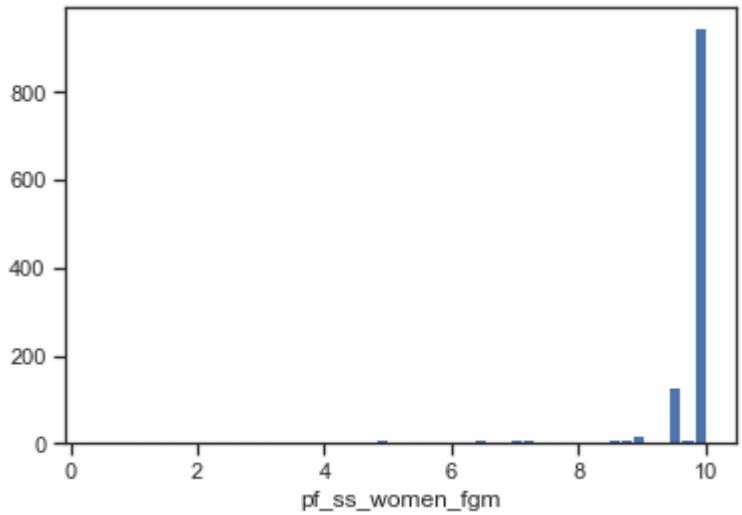
800
600
400
200
0
0
2
4
6
8
10
pf_ss_women_fgm

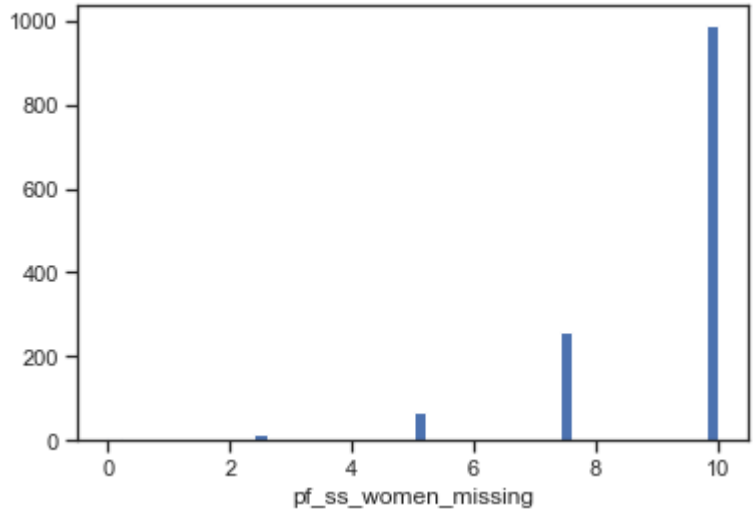
1000
800
600
400
200
0
0
2
4
6
8
10
pf_ss_women_missing

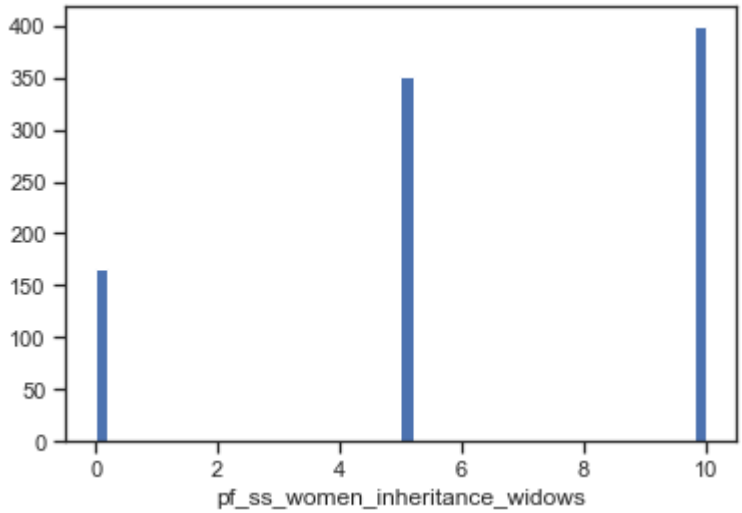
400
350
300
250
200
150
100
50
0
0
2
4
6
8
10
pf_ss_women_inheritance_widows

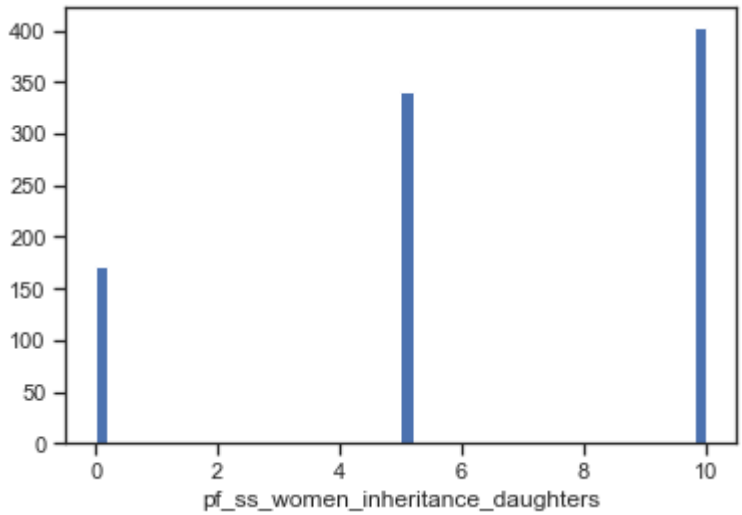
400
350
300
250
200
150
100
50
0
0
2
4
6
8
10
pf_ss_women_inheritance_daughters

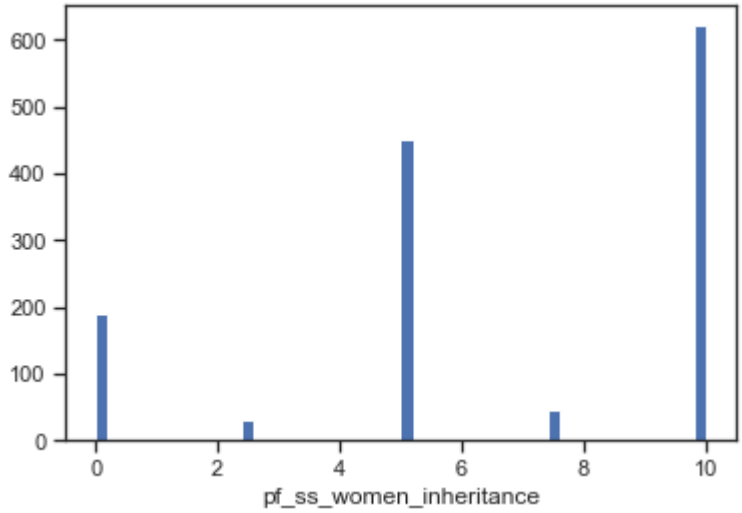
600
500
400
300
200
100
0
0
2
4
6
8
10
pf_ss_women_inheritance

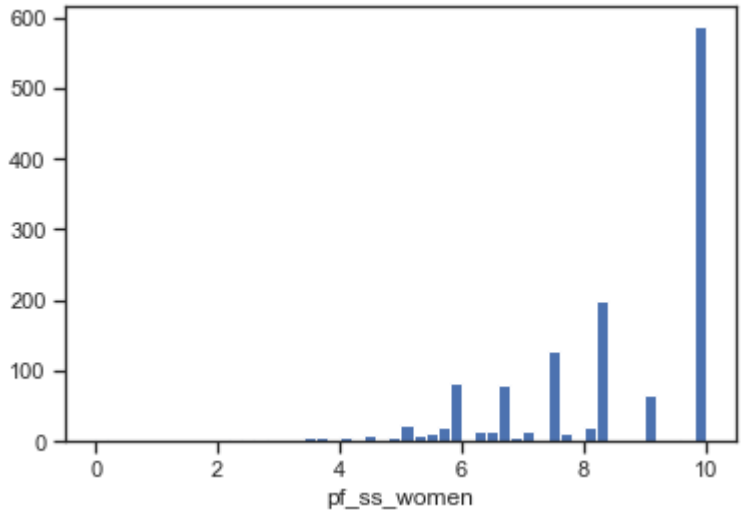
600
500
400
300
200
100
0
0
2
4
6
8
10
pf_ss_women

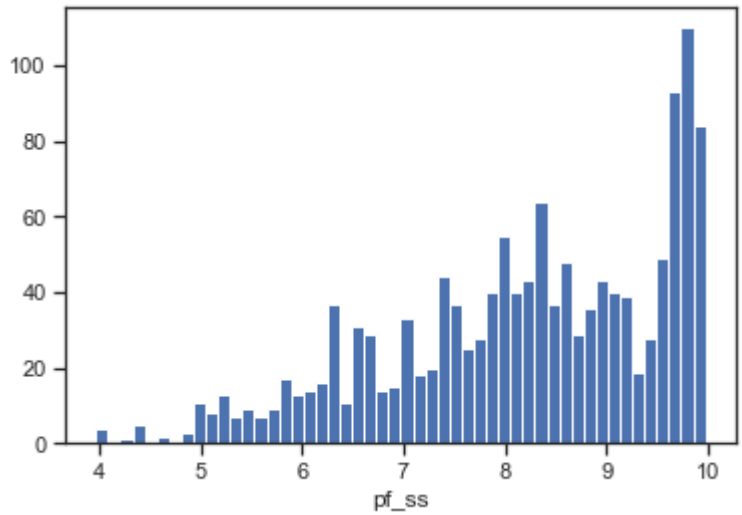
100
80
60
40
20
0
4
5
6
7
8
9
10
pf_ss

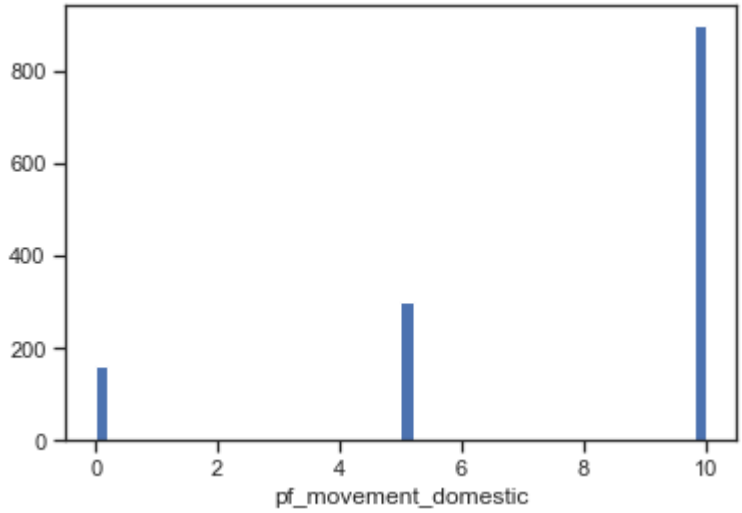
800
600
400
200
0
0
2
4
6
8
10
pf_movement_domestic

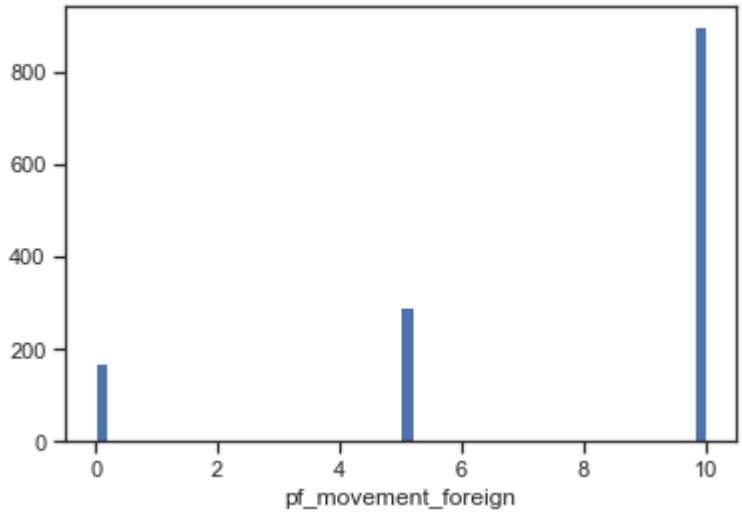
800
600
400
200
0
0
2
4
6
8
10
pf_movement_foreign

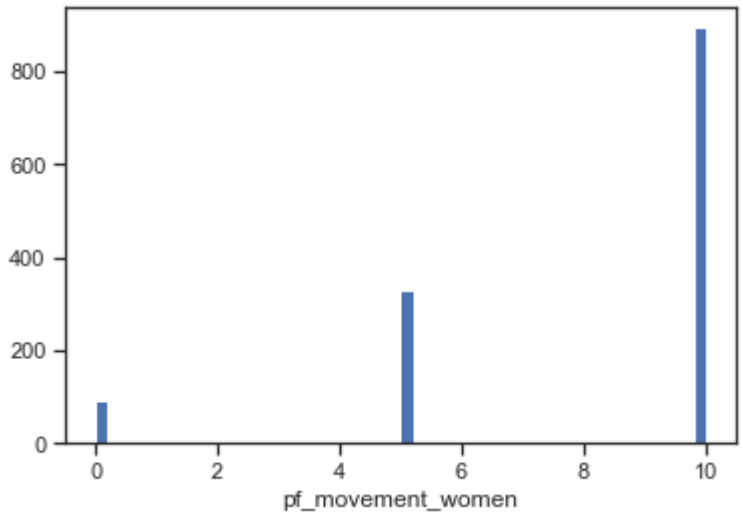
800
600
400
200
0
0
2
4
6
8
10
pf_movement_women

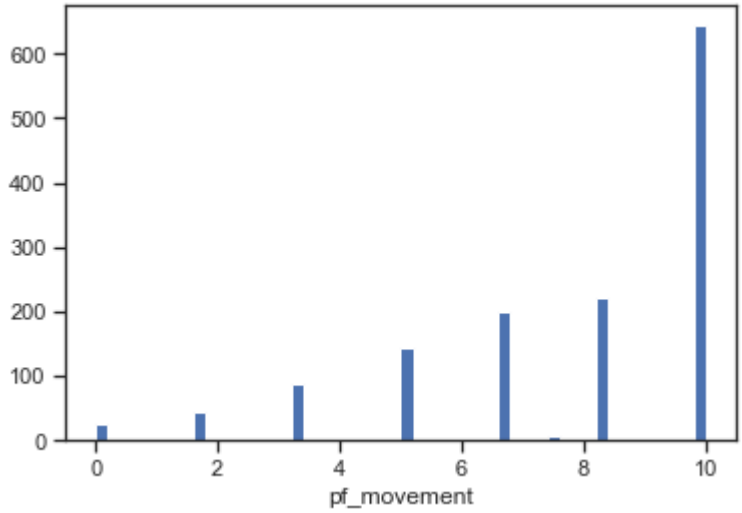
600
500
400
300
200
100
0
0
2
4
6
8
10
pf_movement

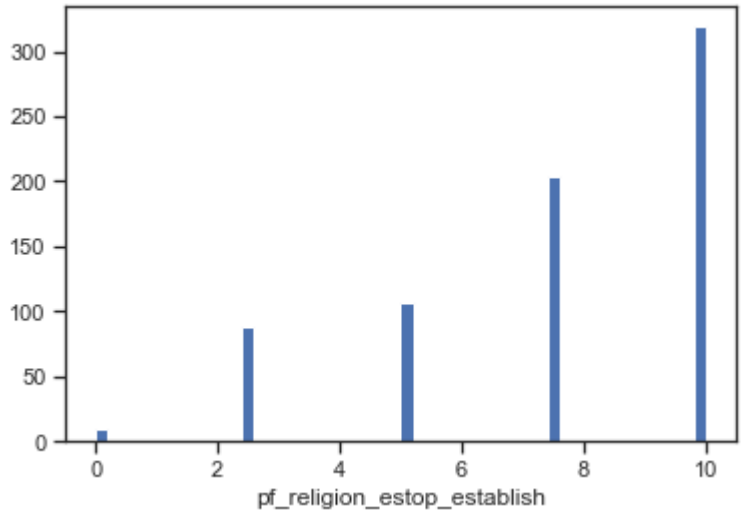
300
250
200
150
100
50
0
0
2
4
6
8
10
pf_religion_estop_establish

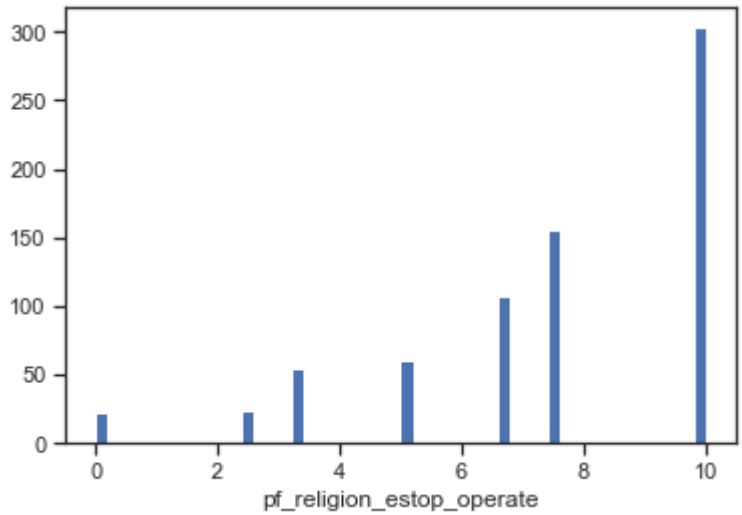
300
250
200
150
100
50
0
0
2
4
6
8
10
pf_religion_estop_operate

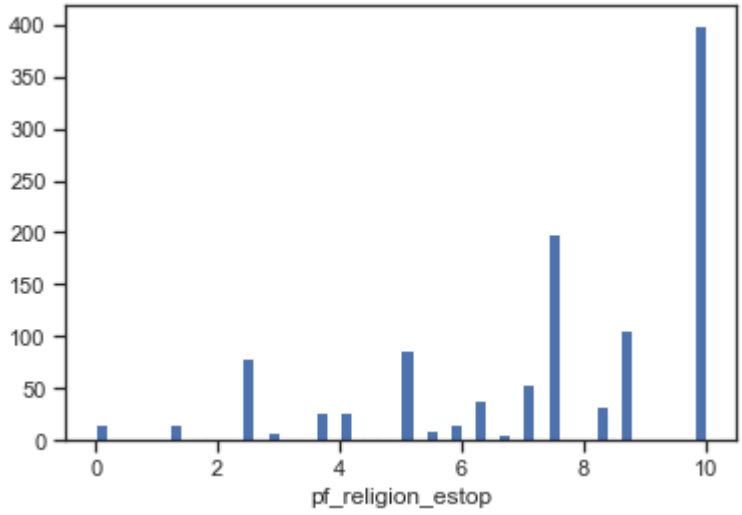
400
350
300
250
200
150
100
50
0
0
2
4
6
8
10
pf_religion_estop

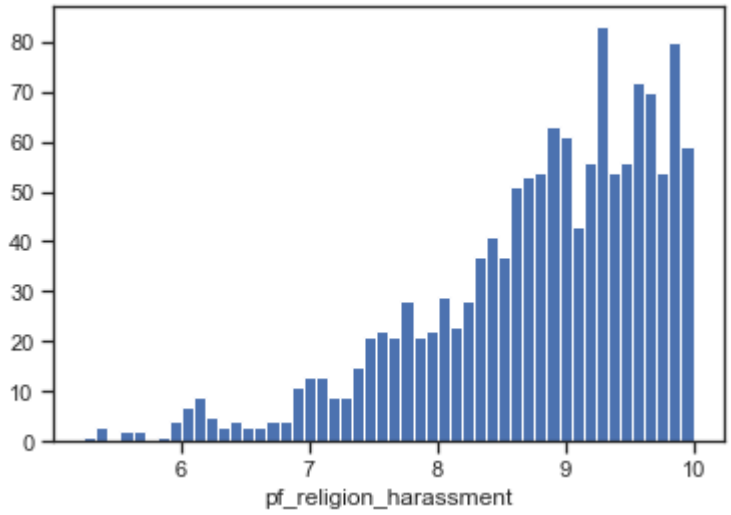
80
70
60
50
40
30
20
10
0
6
7
8
9
10
pf_religion_harassment

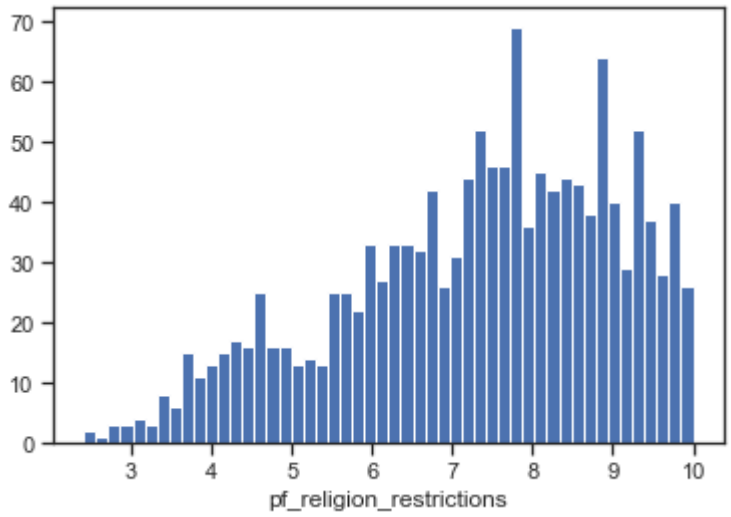
70
60
50
40
30
20
10
0
3
4
5
6
7
8
9
10
pf_religion_restrictions

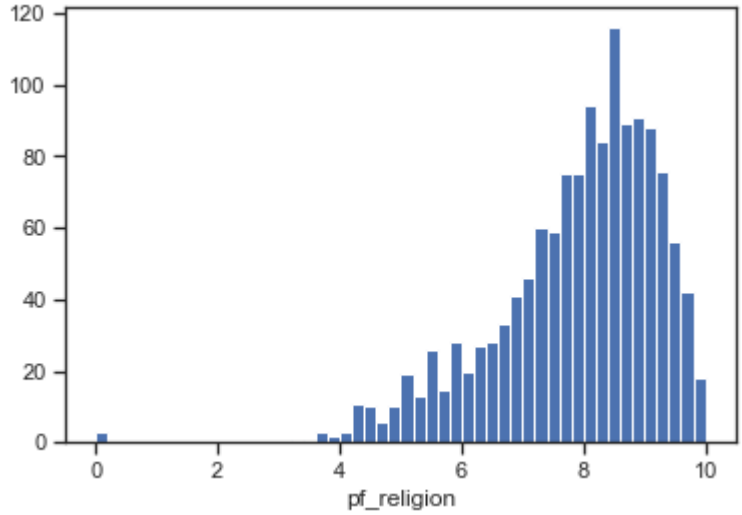
120
100
80
60
40
20
0
0
2
4
6
8
10
pf_religion

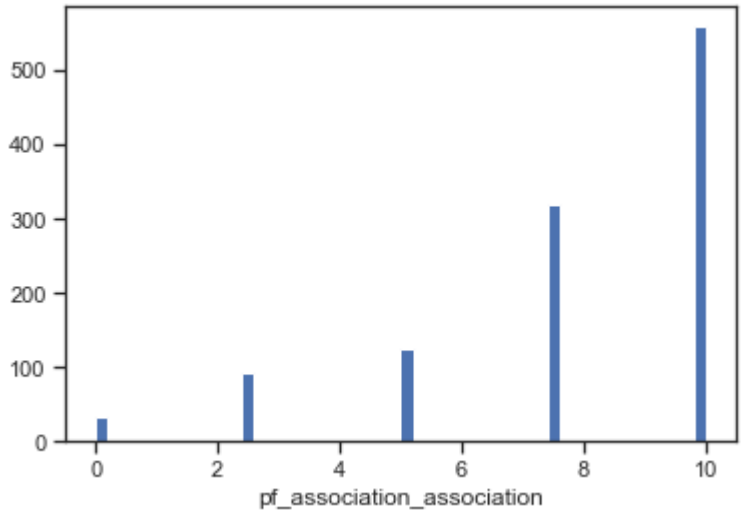
500
400
300
200
100
0
0
2
4
6
8
10
pf_association_association

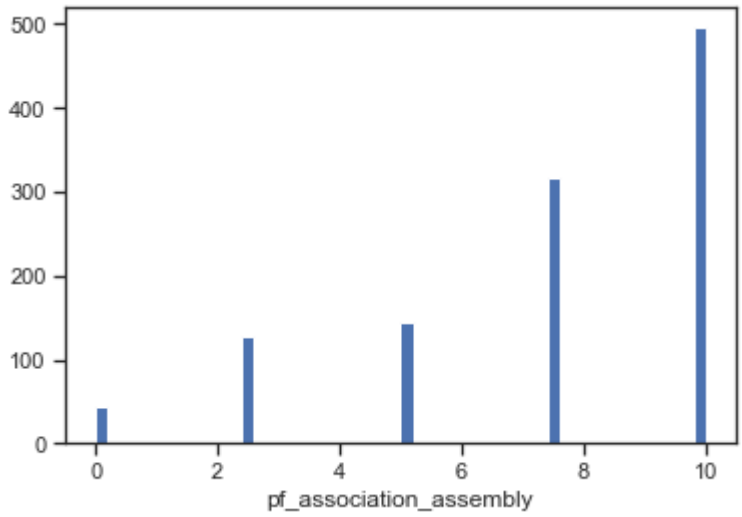
500
400
300
200
100
0
0
2
4
6
8
10
pf_association_assembly

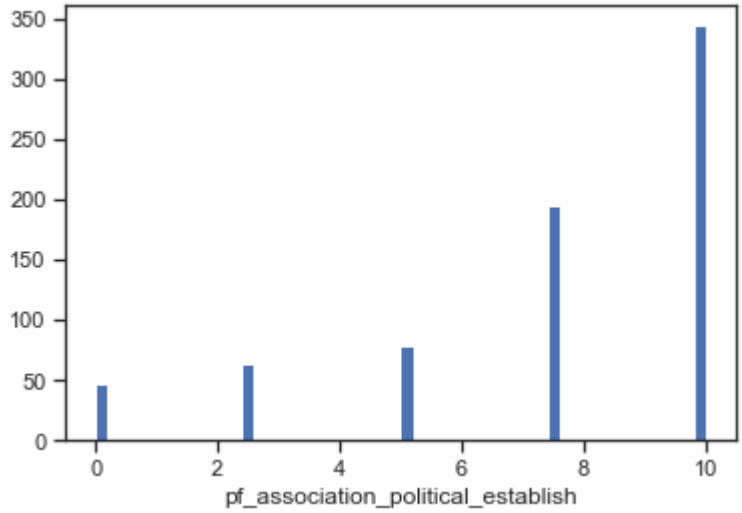
350
300
250
200
150
100
50
0
0
2
4
6
8
10
pf_association_political_establish

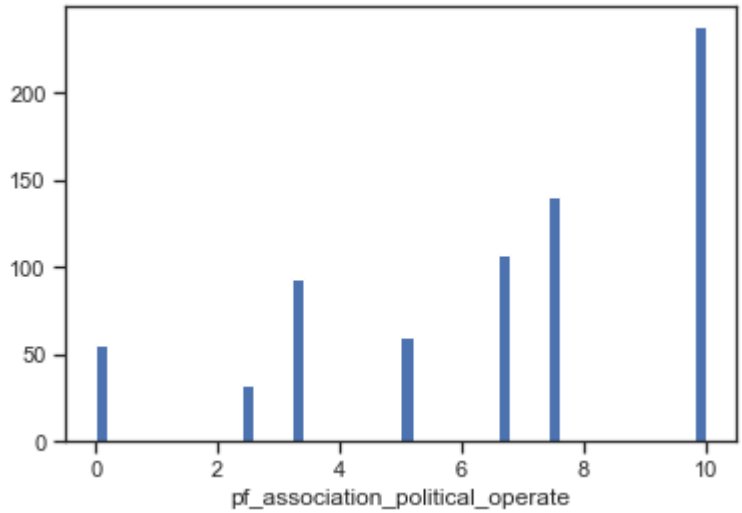
200
150
100
50
0
0
2
4
6
8
10
pf_association_political_operate

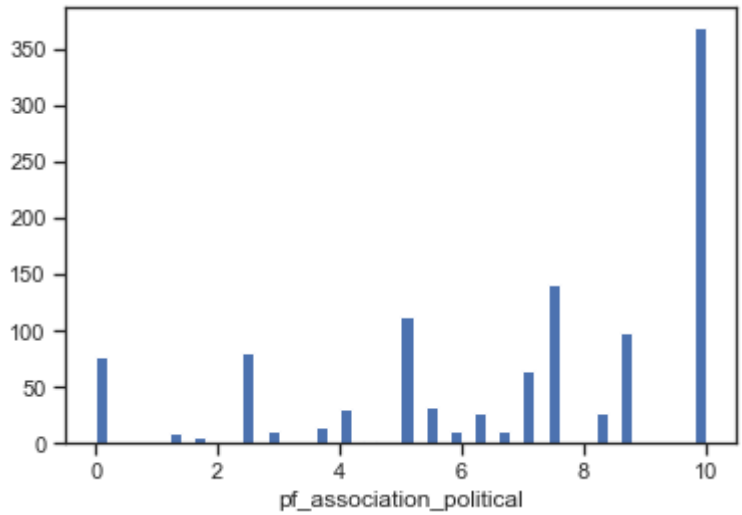
350
300
250
200
150
100
50
0
0
2
4
6
8
10
pf_association_political

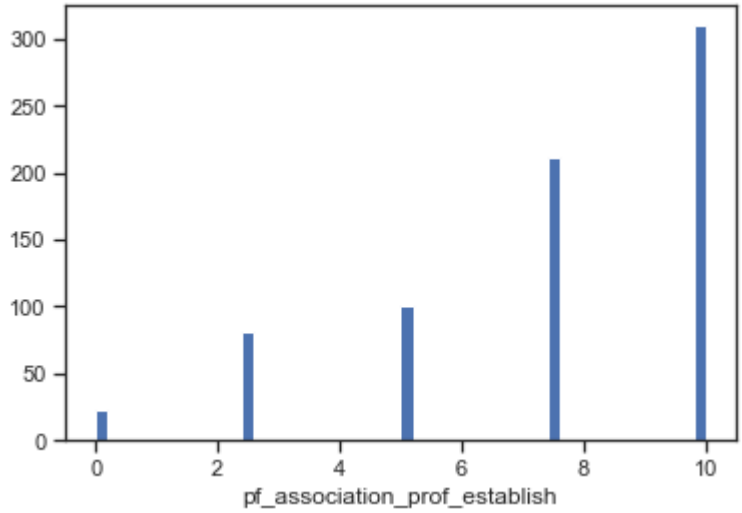
300
250
200
150
100
50
0
0
2
4
6
8
10
pf_association_prof_establish

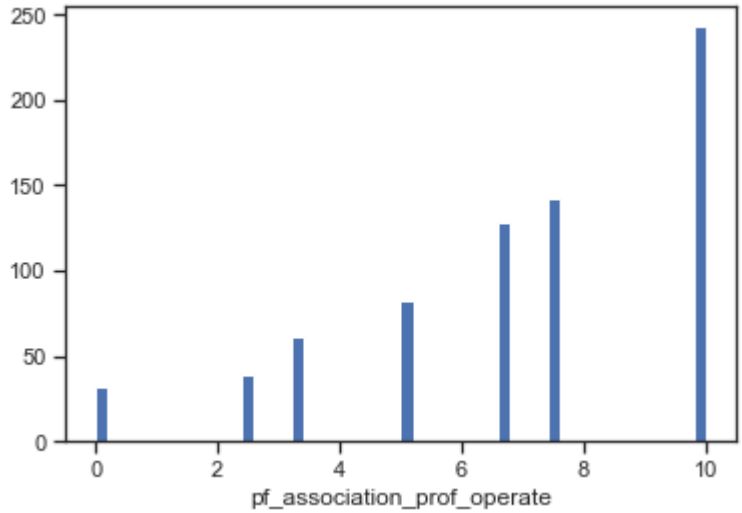
250
200
150
100
50
0
0
2
4
6
8
10
pf_association_prof_operate

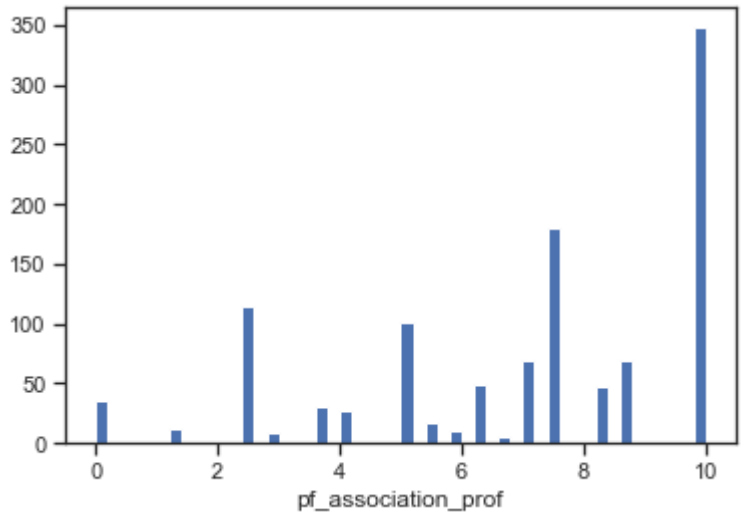
350
300
250
200
150
100
50
0
0
2
4
6
8
10
pf_association_prof

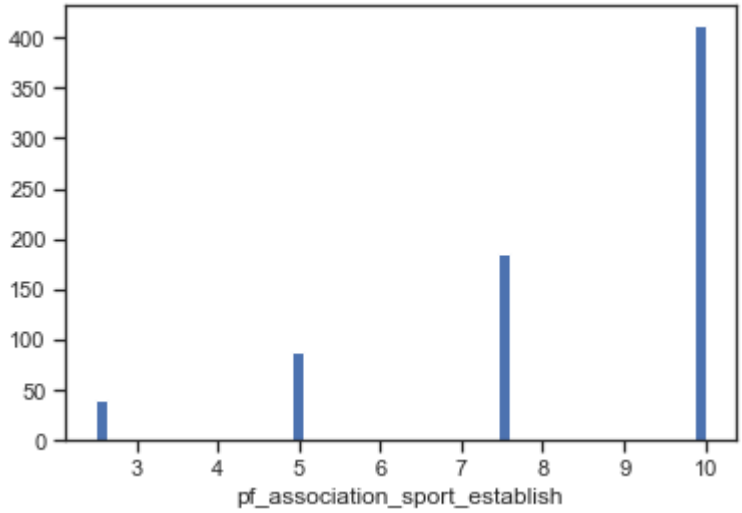
400
350
300
250
200
150
100
50
0
3
4
5
6
7
8
9
10
pf_association_sport_establish

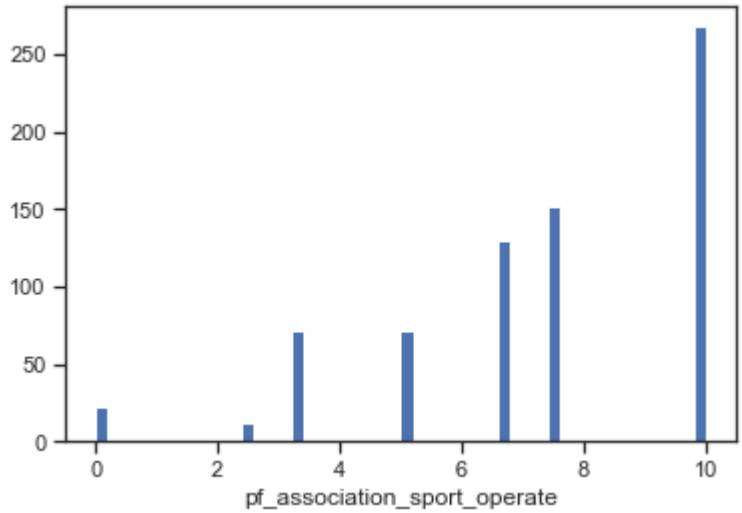
250
200
150
100
50
0
0
2
4
6
8
10
pf_association_sport_operate

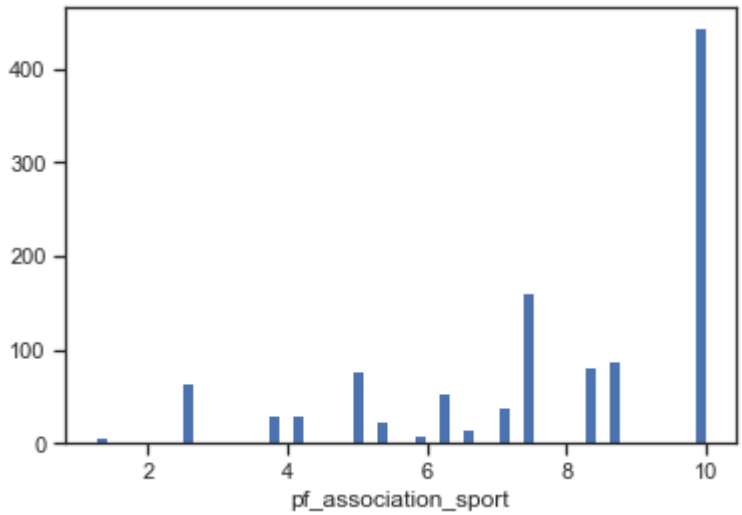
400
300
200
100
0
2
4
6
8
10
pf_association_sport

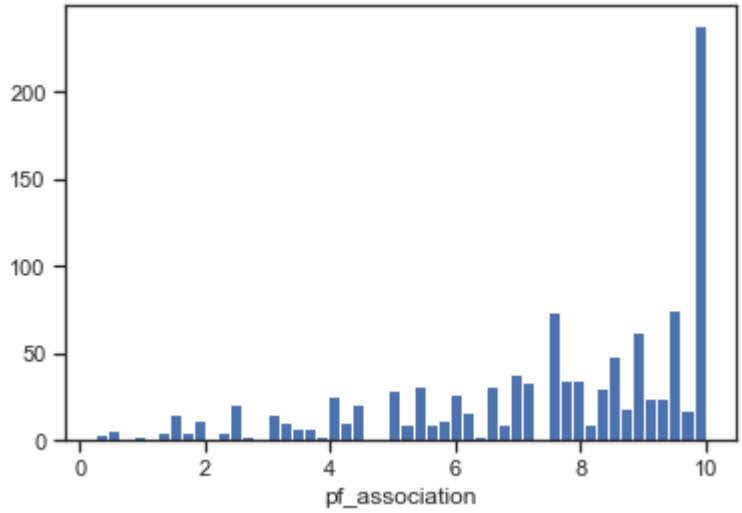
200
150
100
50
0
0
2
4
6
8
10
pf_association

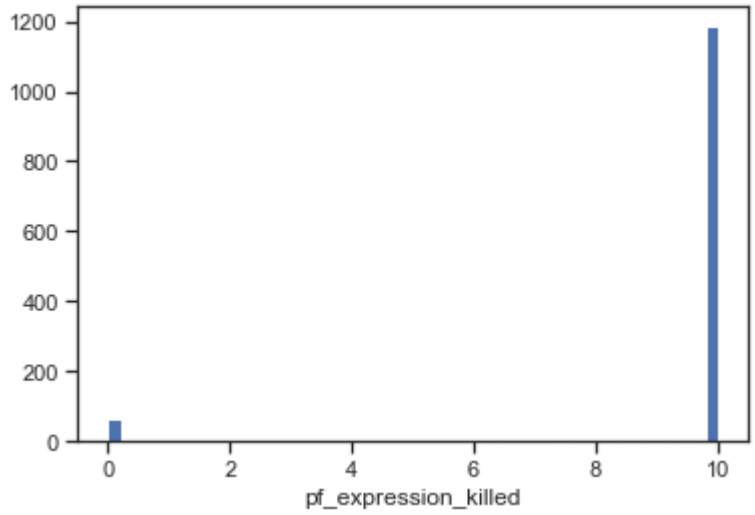
1200
1000
800
600
400
200
0
0
2
4
6
8
10
pf_expression_killed

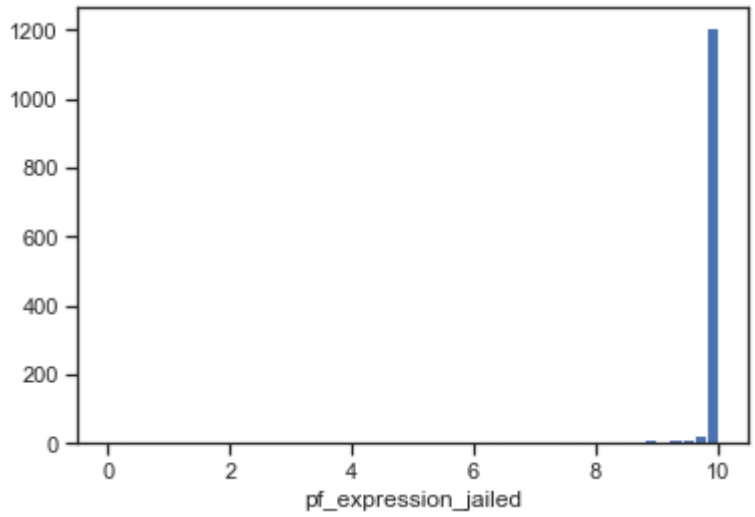
1200
1000
800
600
400
200
0
0
2
4
6
8
10
pf_expression_jailed

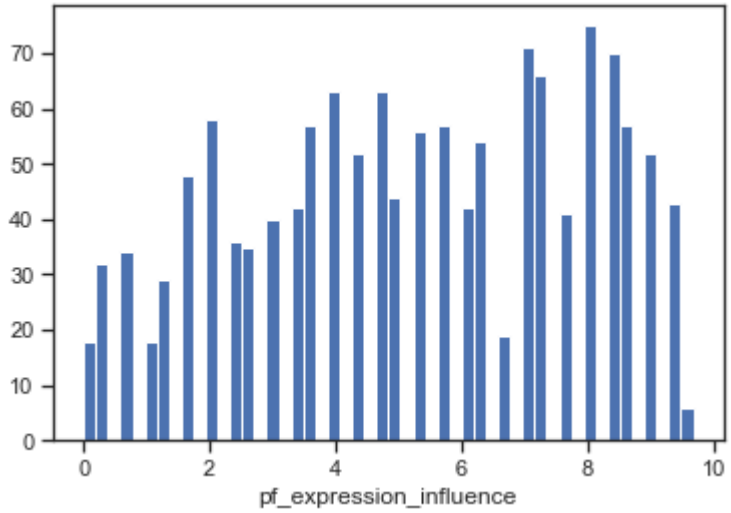
70
60
50
40
30
20
10
0
0
2
4
6
8
10
pf_expression_influence

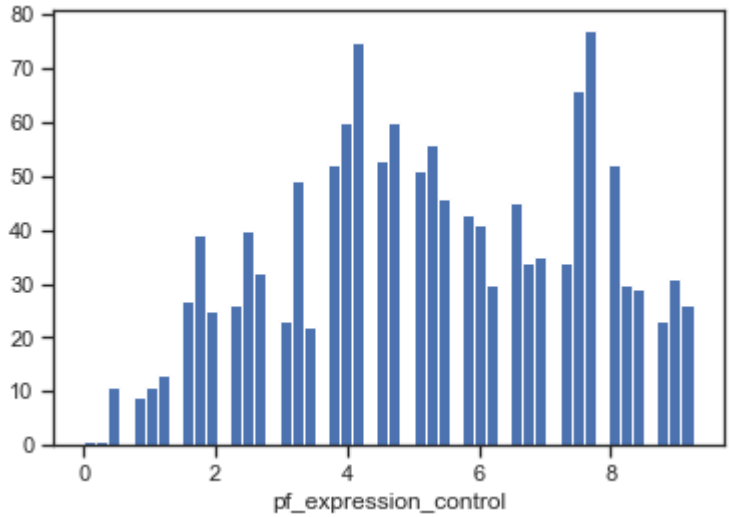
80
70
60
50
40
30
20
10
0
0
2
4
6
8
pf_expression_control

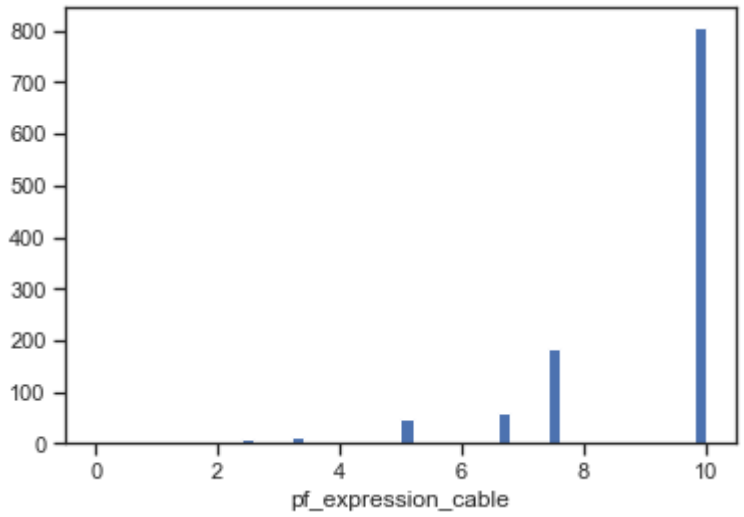
800
700
600
500
400
300
200
100
0
0
2
4
6
8
10
pf_expression_cable

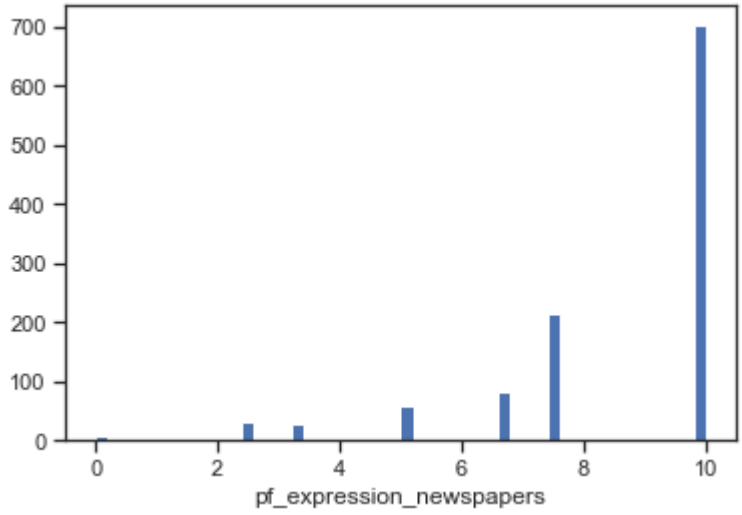
700
600
500
400
300
200
100
0
0
2
4
6
8
10
pf_expression_newspapers

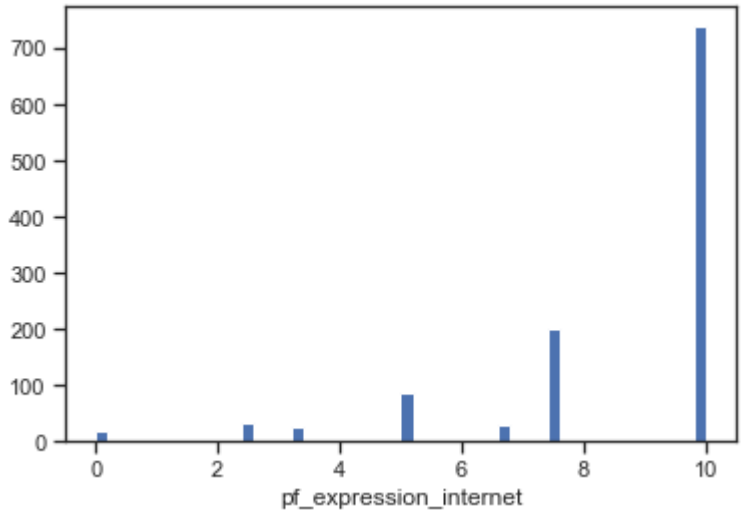
700
600
500
400
300
200
100
0
0
2
4
6
8
10
pf_expression_internet

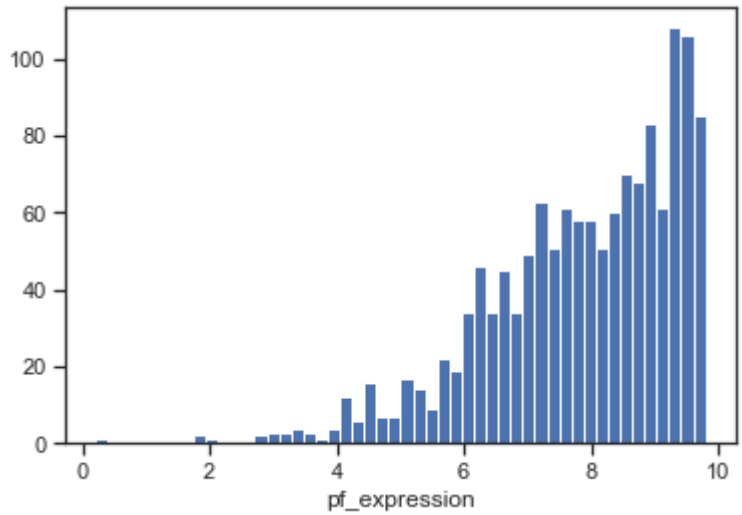
100
80
60
40
20
0
0
2
4
6
8
10
pf_expression

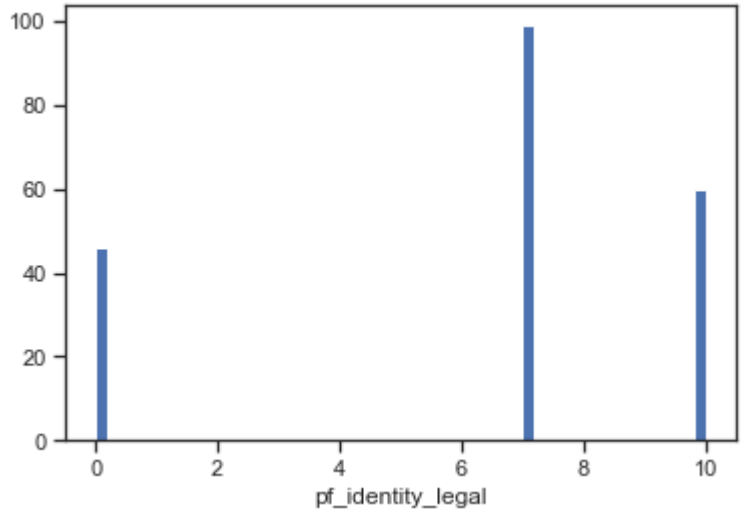
100
80
60
40
20
0
0
2
4
6
8
10
pf_identity_legal

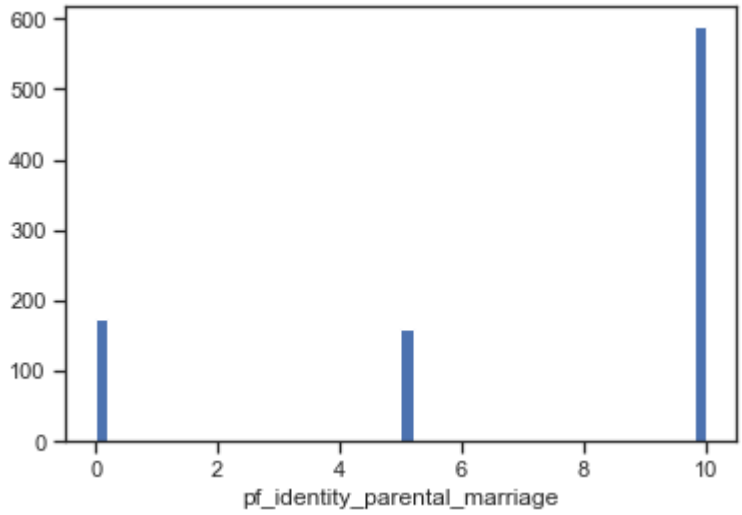
600
500
400
300
200
100
0
0
2
4
6
8
10
pf_identity_parental_marriage

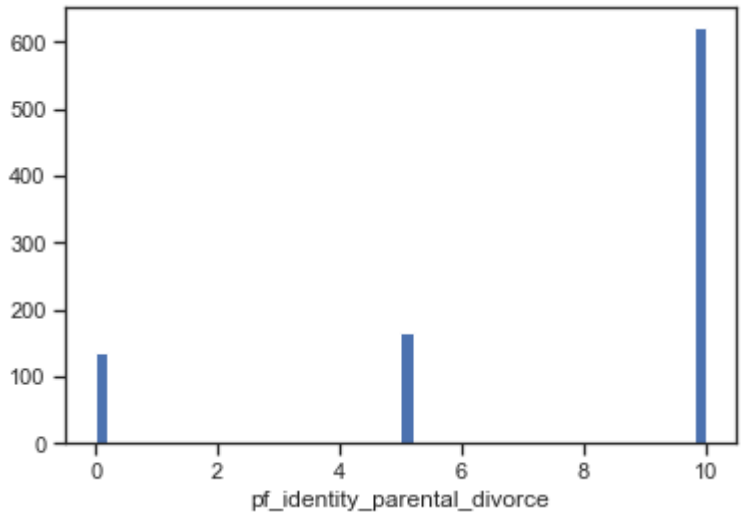
600
500
400
300
200
100
0
0
2
4
6
8
10
pf_identity_parental_divorce

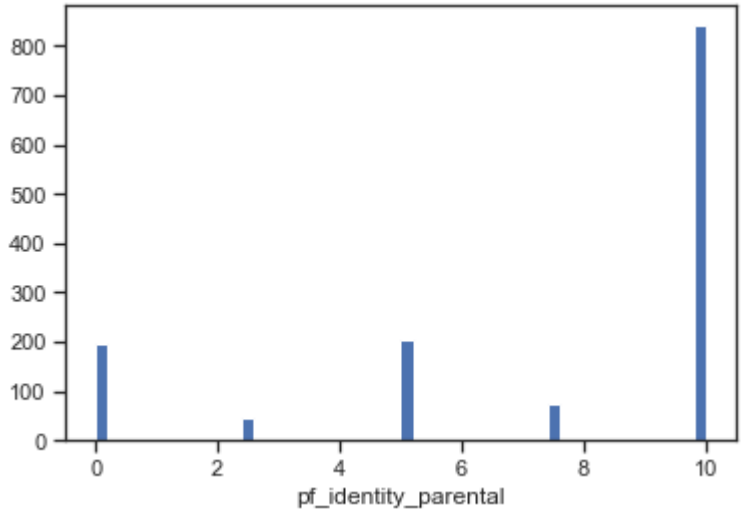
800
700
600
500
400
300
200
100
0
0
2
4
6
8
10
pf_identity_parental

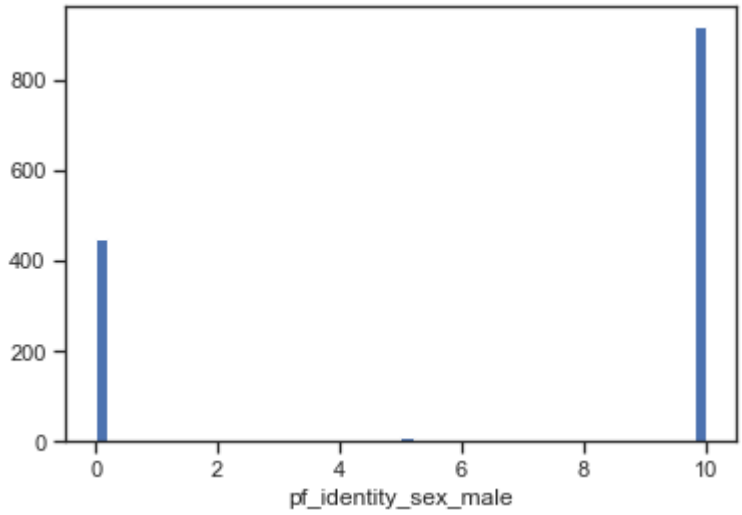
800
600
400
200
0
0
2
4
6
8
10
pf_identity_sex_male

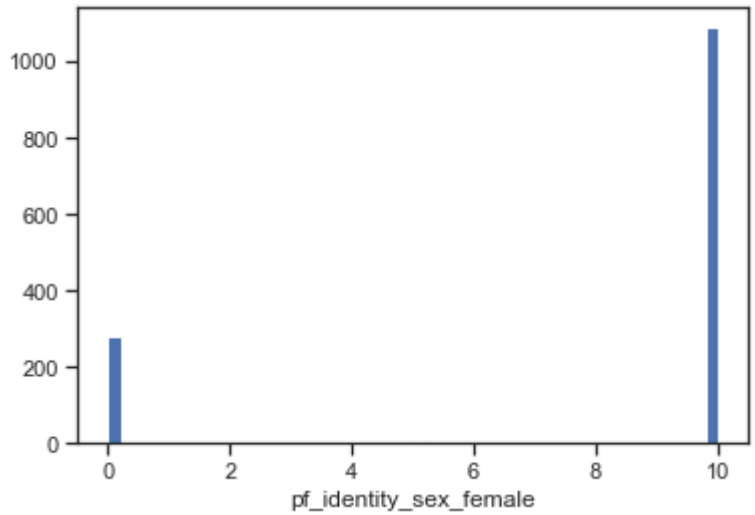
1000
800
600
400
200
0
0
2
4
6
8
10
pf_identity_sex_female

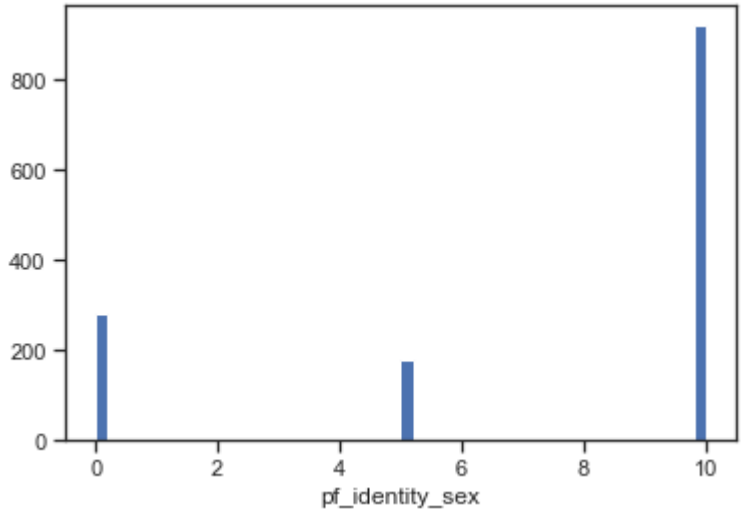
800
600
400
200
0
0
2
4
6
8
10
pf_identity_sex

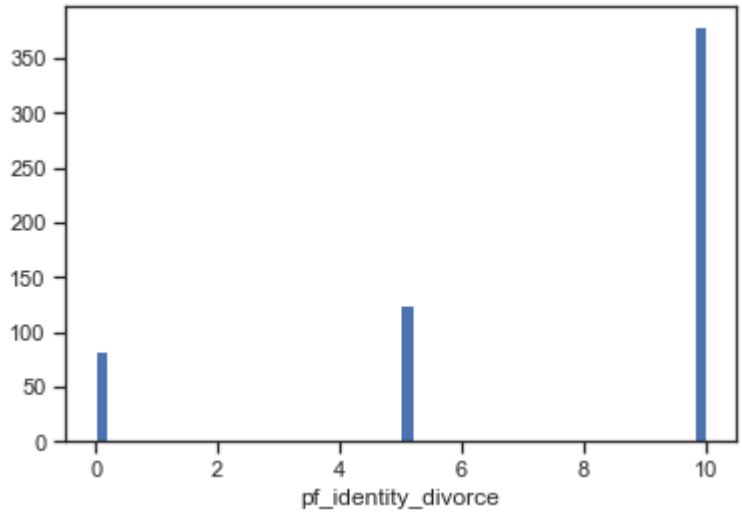
350
300
250
200
150
100
50
0
0
2
4
6
8
10
pf_identity_divorce

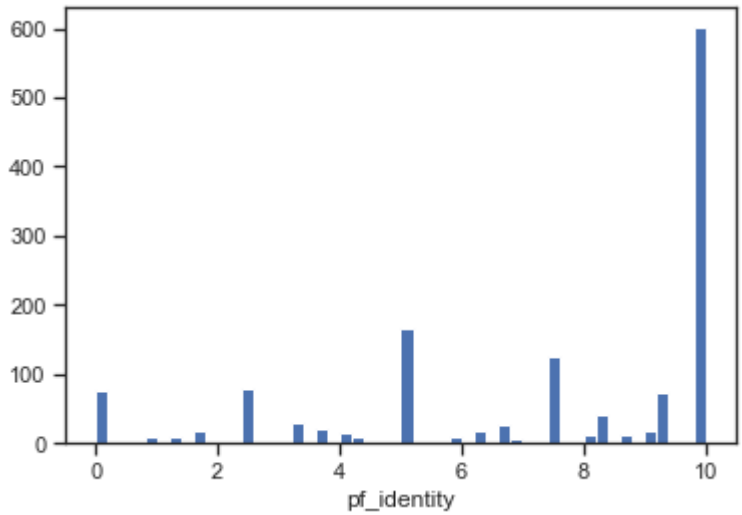
600
500
400
300
200
100
0
0
2
4
6
8
10
pf_identity

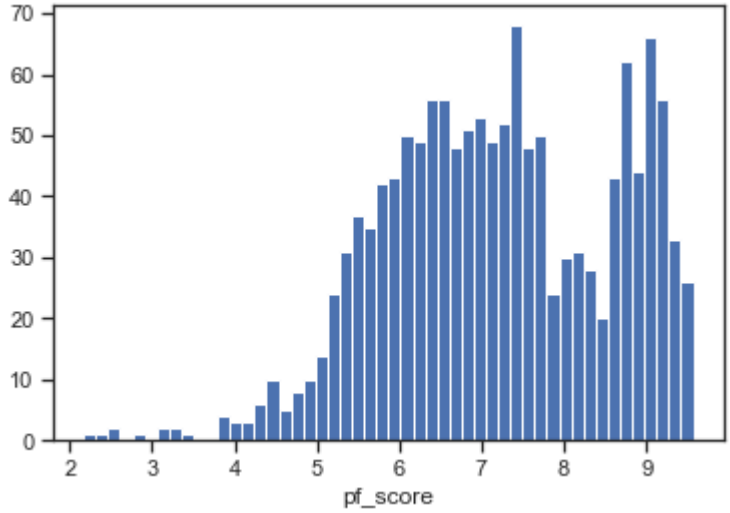
70
60
50
40
30
20
10
0
2
3
4
5
6
7
8
9
pf_score

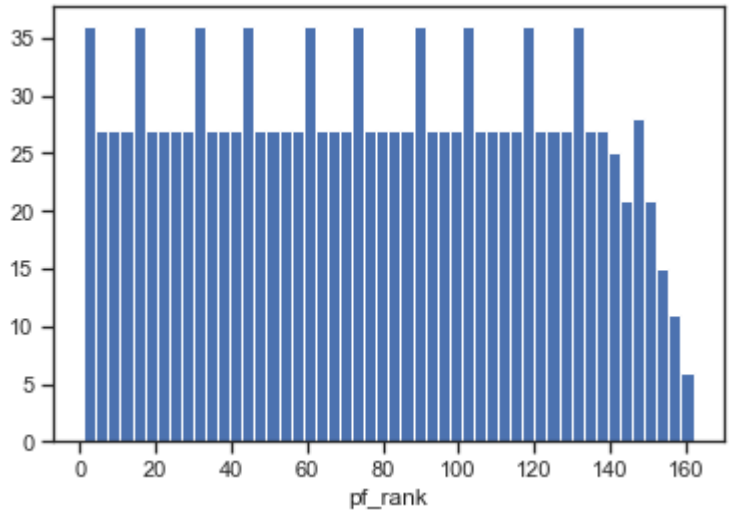
35
30
25
20
15
10
5
0
0
20
40
60
80
100
120
140
160
pf_rank

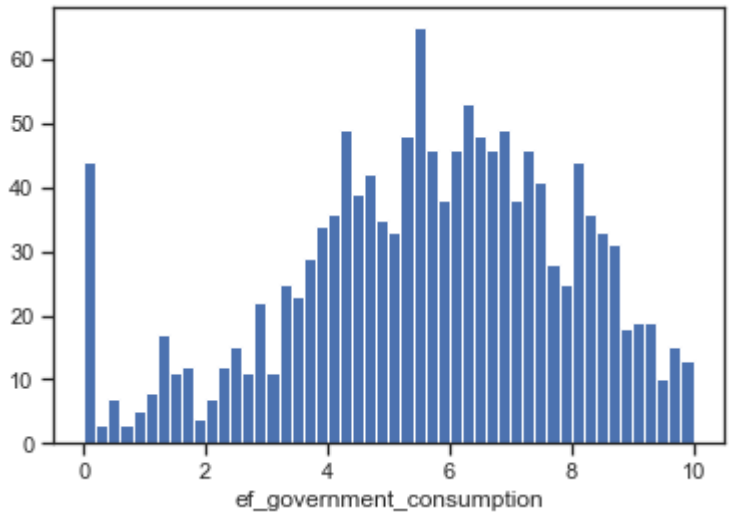
60
50
40
30
20
10
0
0
2
4
6
8
10
ef_government_consumption

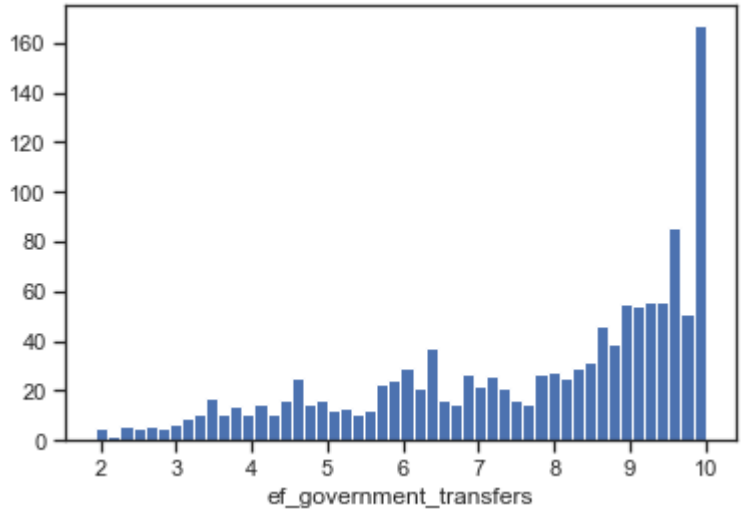
160
140
120
100
80
60
40
20
0
2
3
4
5
6
7
8
9
10
ef_government_transfers

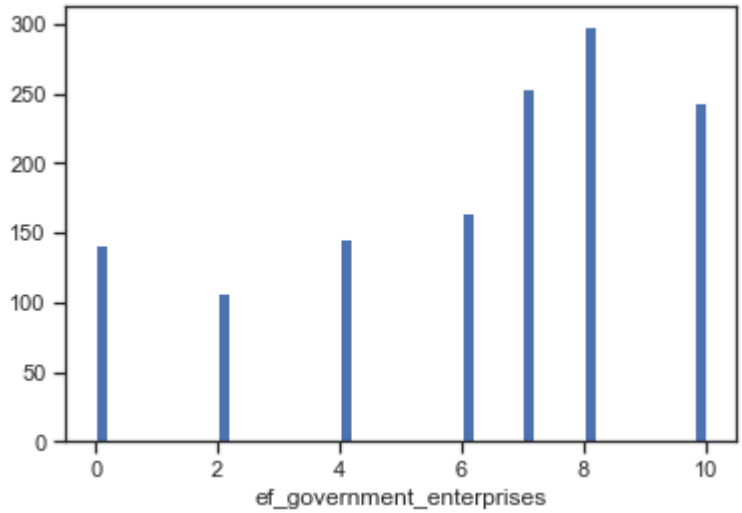
300
250
200
150
100
50
0
0
2
4
6
8
10
ef_government_enterprises

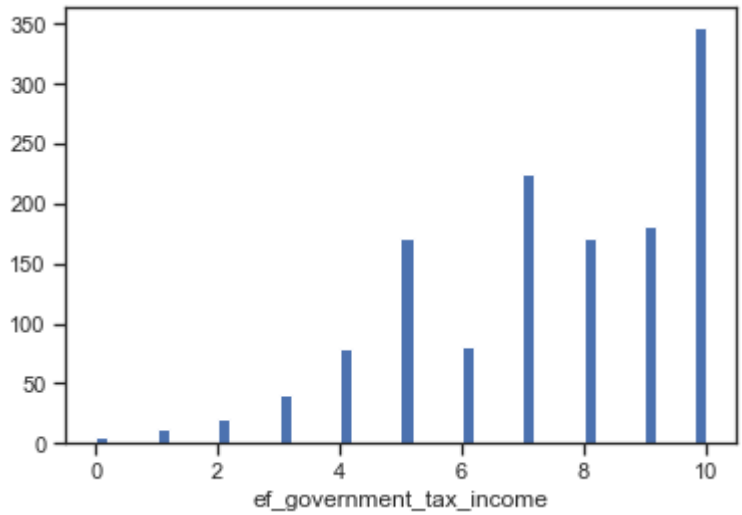
350
300
250
200
150
100
50
0
0
2
4
6
8
10
ef_government_tax_income

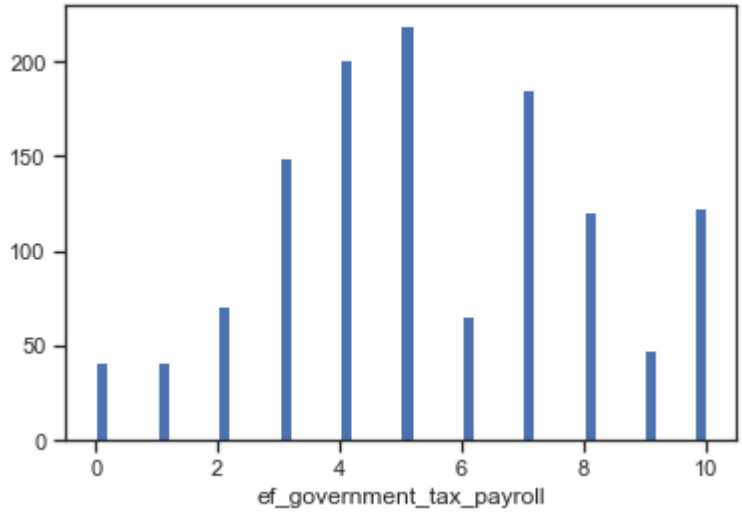
200
150
100
50
0
0
2
4
6
8
10
ef_government_tax_payroll

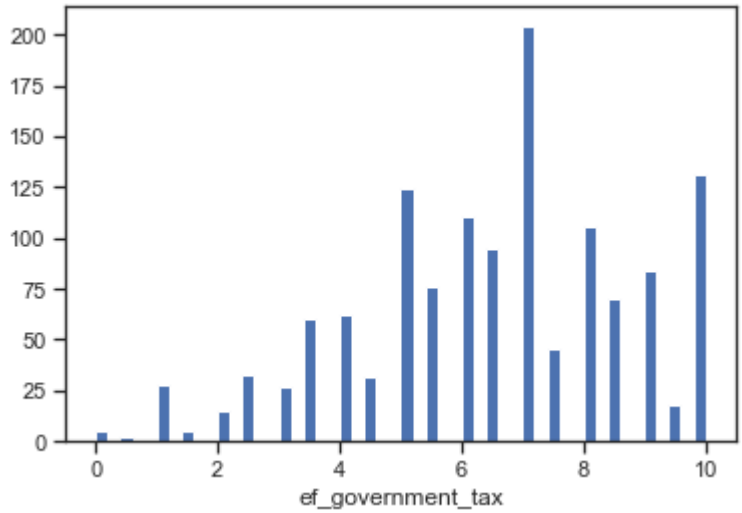
200
175
150
125
100
75
50
25
0
0
2
4
6
8
10
ef_government_tax

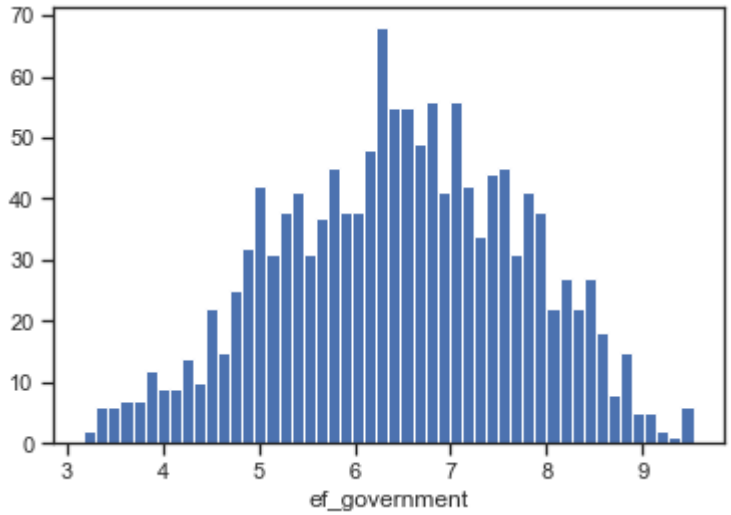
70
60
50
40
30
20
10
0
3
4
5
6
7
8
9
ef_government

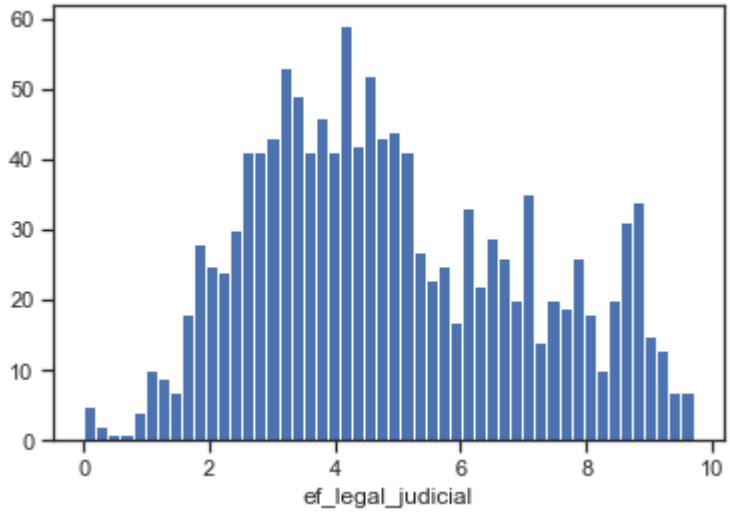
60
50
40
30
20
10
0
0
2
4
6
8
10
ef_legal_judicial

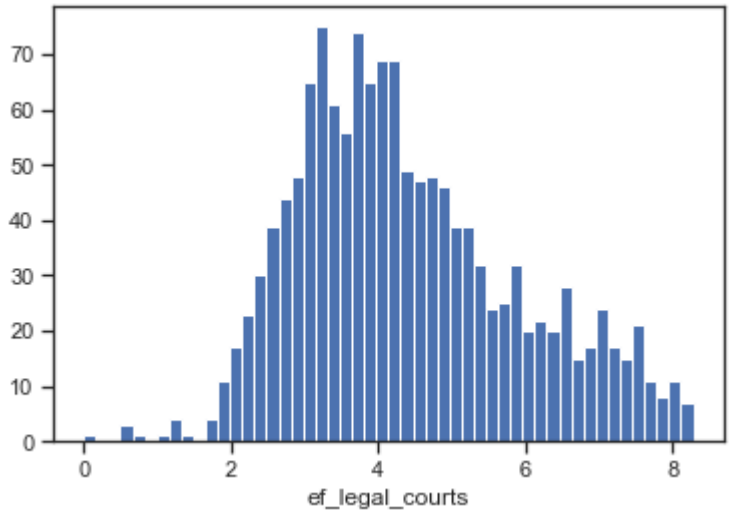
70
60
50
40
30
20
10
0
0
2
4
6
8
ef_legal_courts

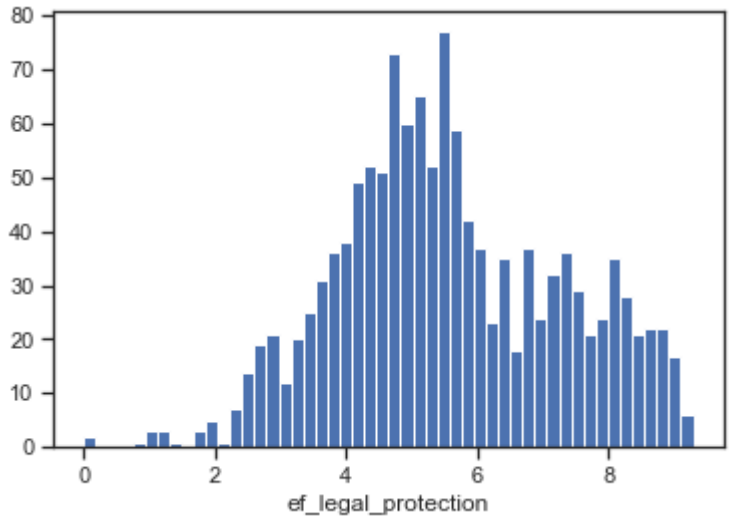
80
70
60
50
40
30
20
10
0
0
2
4
6
8
ef_legal_protection

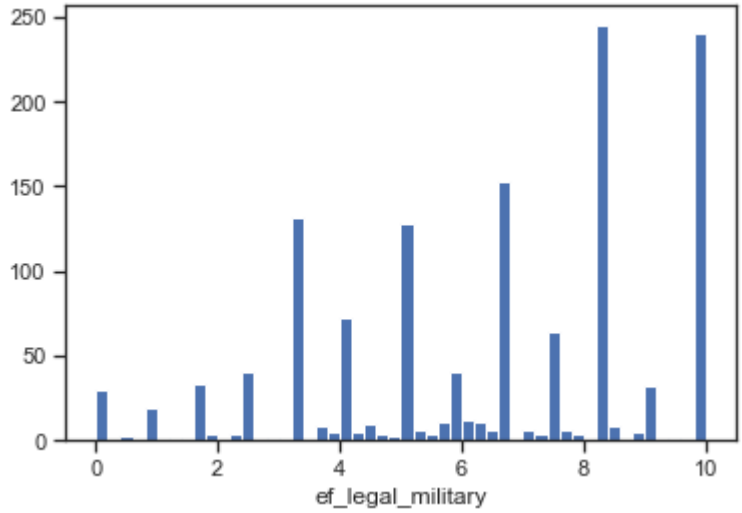
250
200
150
100
50
0
0
2
4
6
8
10
ef_legal_military

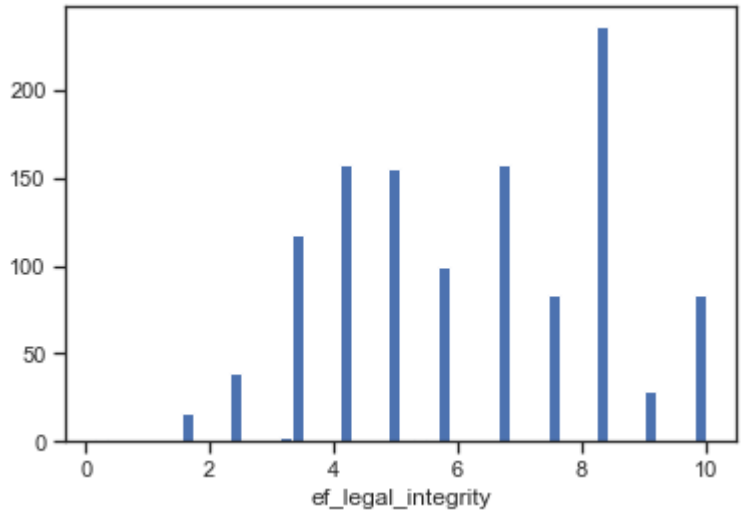
200
150
100
50
0
0
2
4
6
8
10
ef_legal_integrity

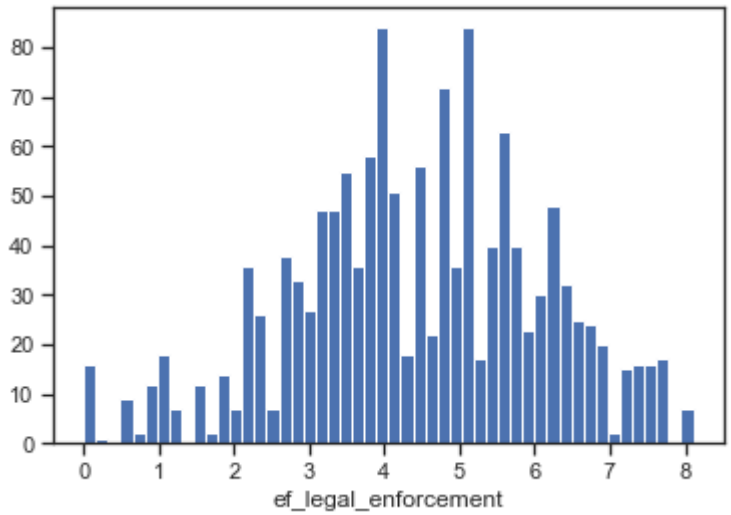
80
70
60
50
40
30
20
10
0
0
1
2
3
4
5
6
7
8
ef_legal_enforcement

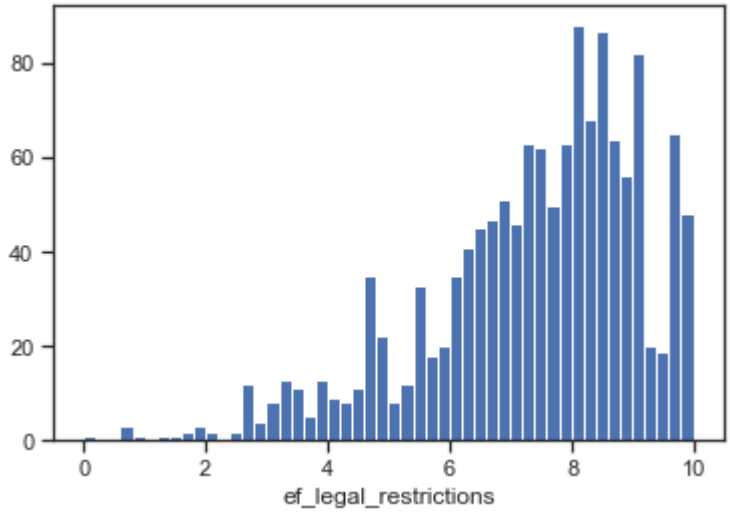
0
20
40
60
80
0
2
4
6
8
10
ef_legal_restrictions

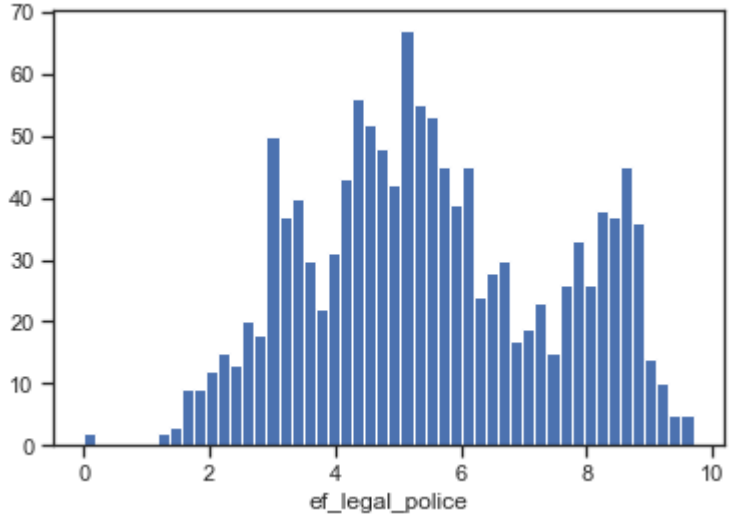
0
10
20
30
40
50
60
70
0
2
4
6
8
10
ef_legal_police

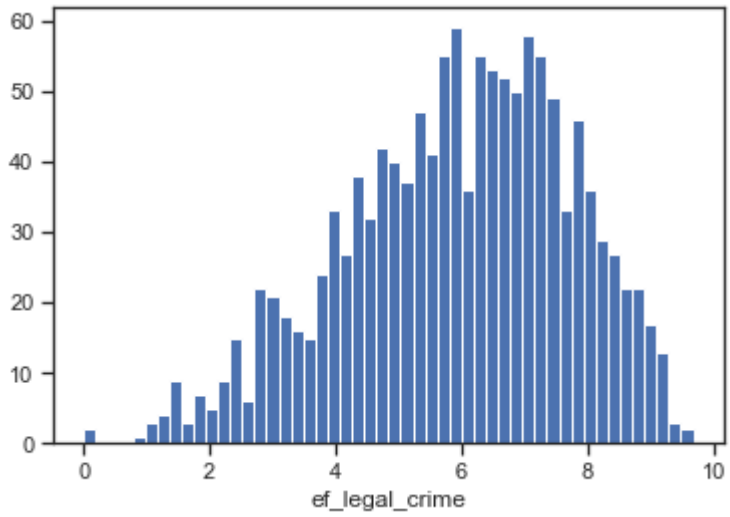
0
10
20
30
40
50
60
0
2
4
6
8
10
ef_legal_crime

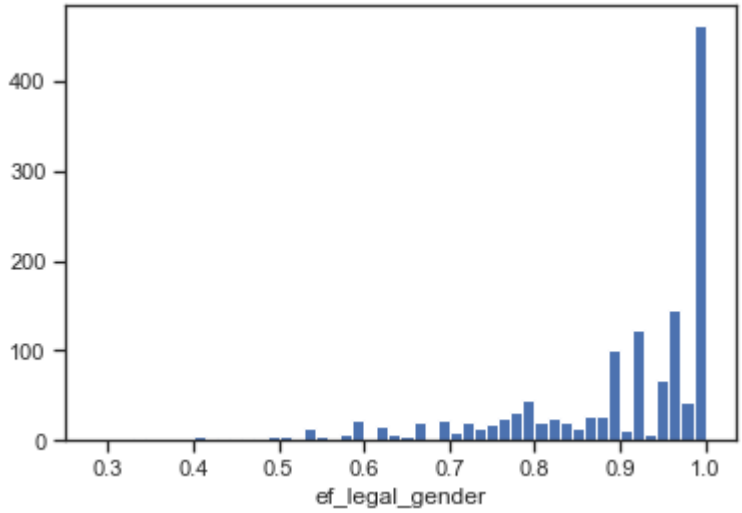
400
300
200
100
0
0.3
0.4
0.5
0.6
0.7
0.8
0.9
1.0
ef_legal_gender

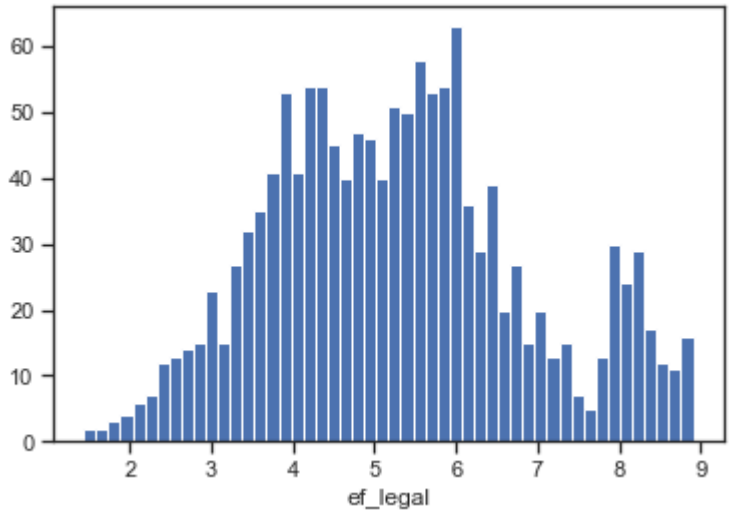
60
50
40
30
20
10
0
2
3
4
5
6
7
8
9
ef_legal

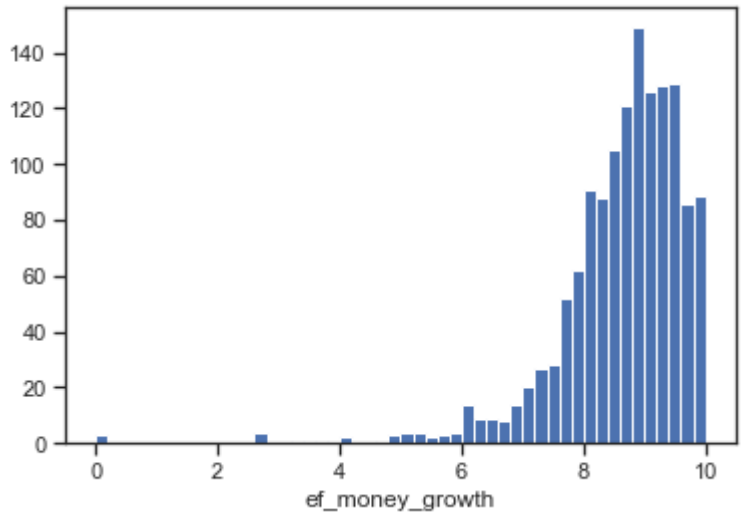
140
120
100
80
60
40
20
0
0
2
4
6
8
10
ef_money_growth

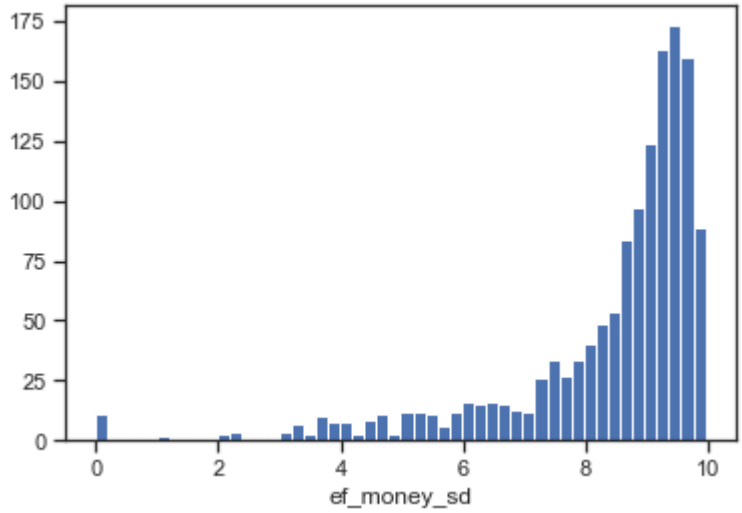
175
150
125
100
75
50
25
0
0
2
4
6
8
10
ef_money_sd

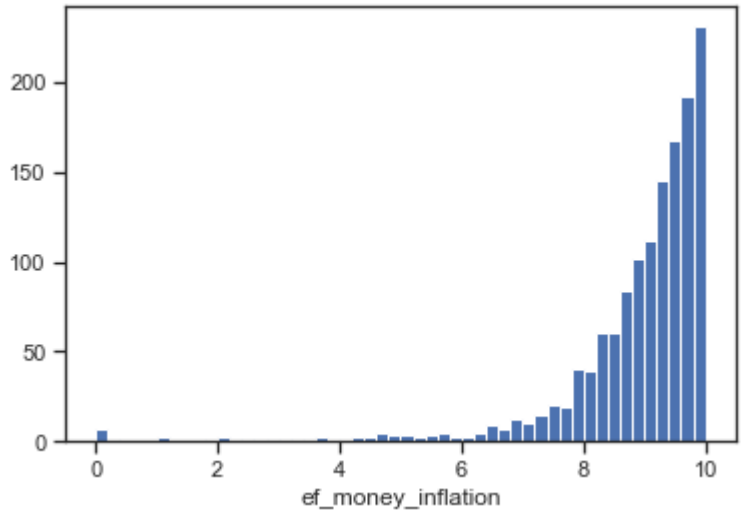
200
150
100
50
0
0
2
4
6
8
10
ef_money_inflation

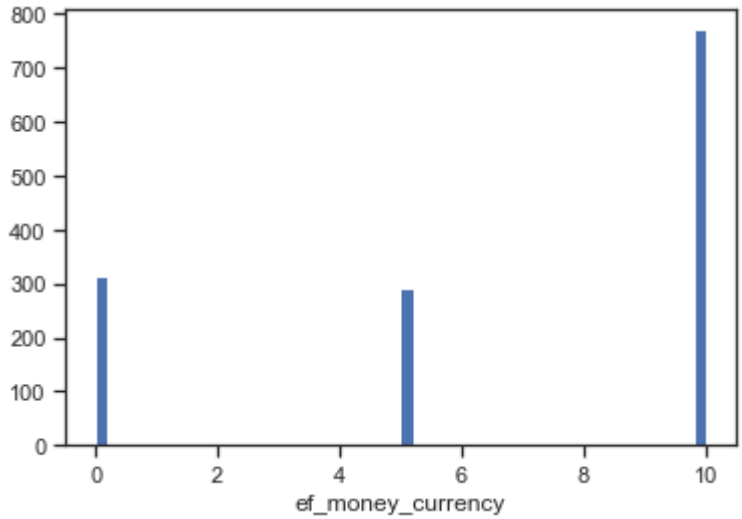
800
700
600
500
400
300
200
100
0
0
2
4
6
8
10
ef_money_currency

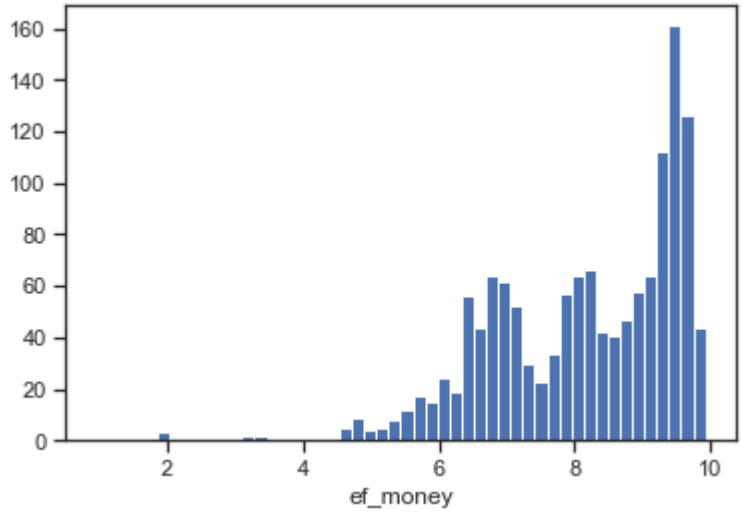
160
140
120
100
80
60
40
20
0
2
4
6
8
10
ef_money

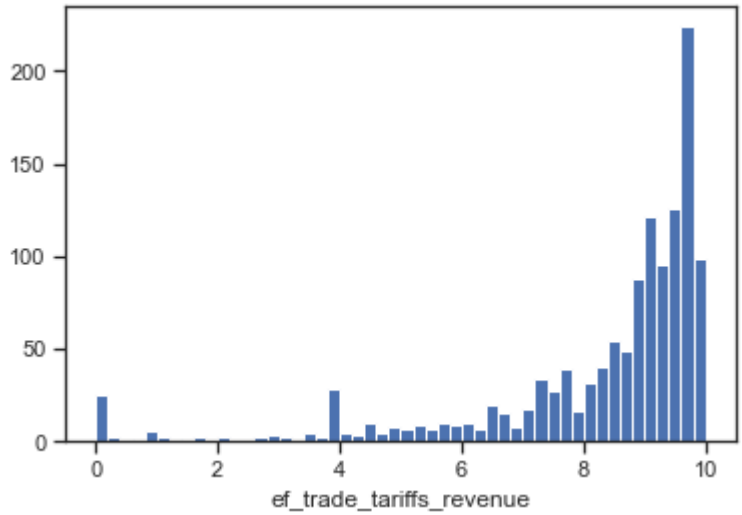
200
150
100
50
0
0
2
4
6
8
10
ef_trade_tariffs_revenue

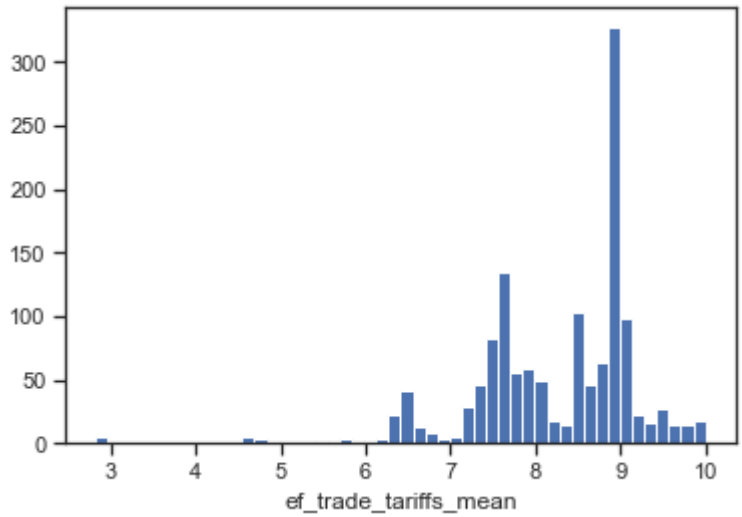
300
250
200
150
100
50
0
3
4
5
6
7
8
9
10
ef_trade_tariffs_mean

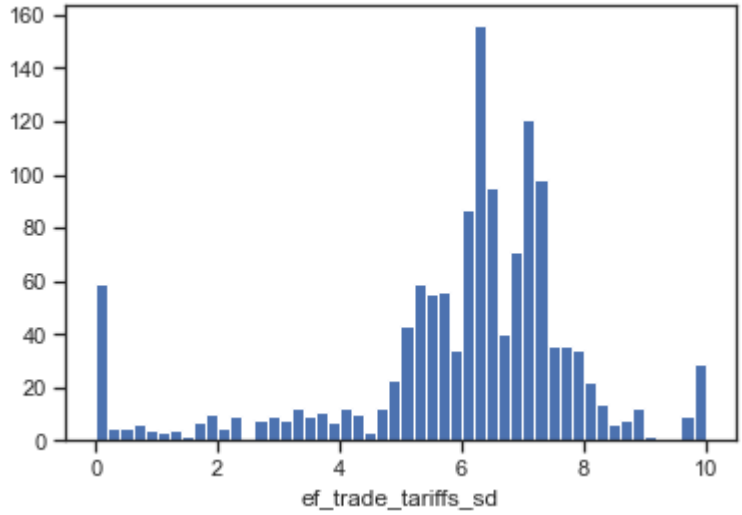
160
140
120
100
80
60
40
20
0
0
2
4
6
8
10
ef_trade_tariffs_sd

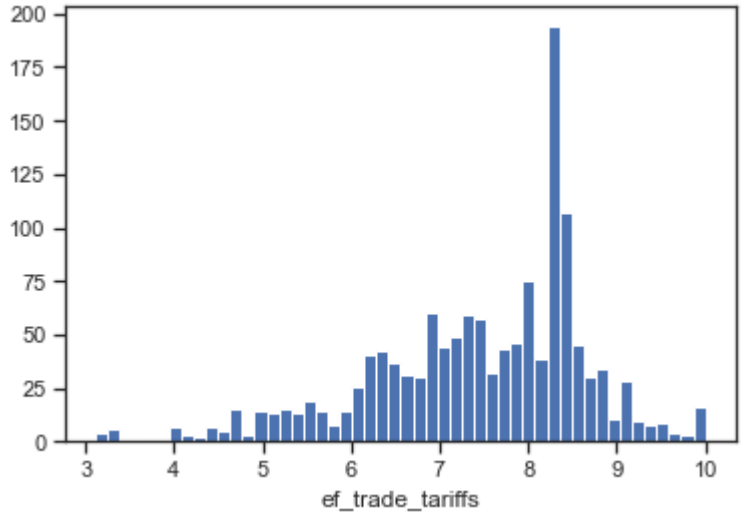
200
175
150
125
100
75
50
25
0
3
4
5
6
7
8
9
10
ef_trade_tariffs

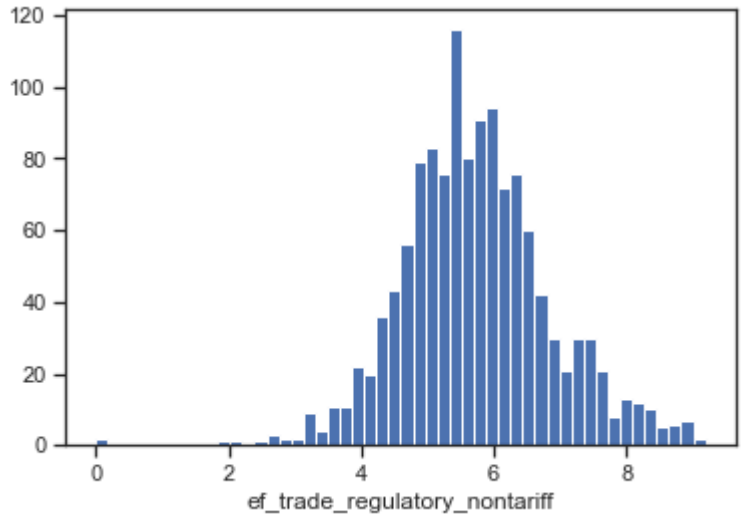
120
100
80
60
40
20
0
0
2
4
6
8
ef_trade_regulatory_nontariff

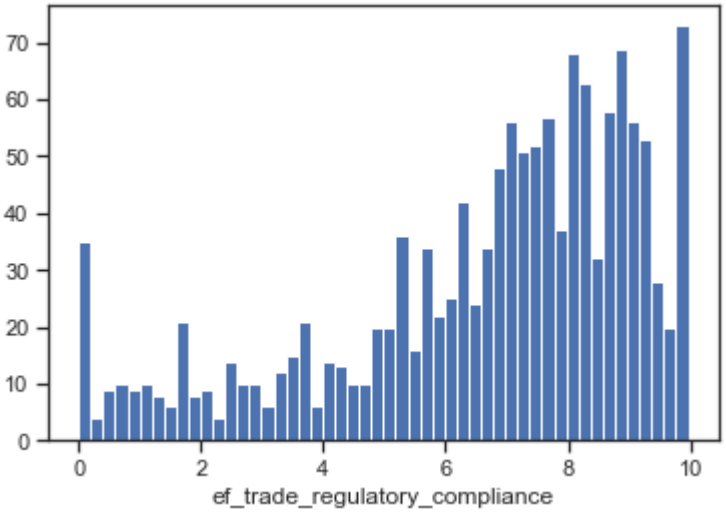
70
60
50
40
30
20
10
0
0
2
4
6
8
10
ef_trade_regulatory_compliance

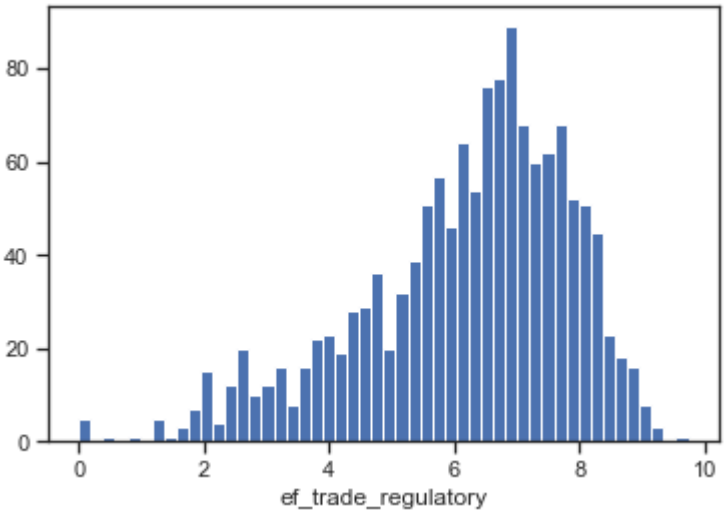
80
60
40
20
0
0
2
4
6
8
10
ef_trade_regulatory

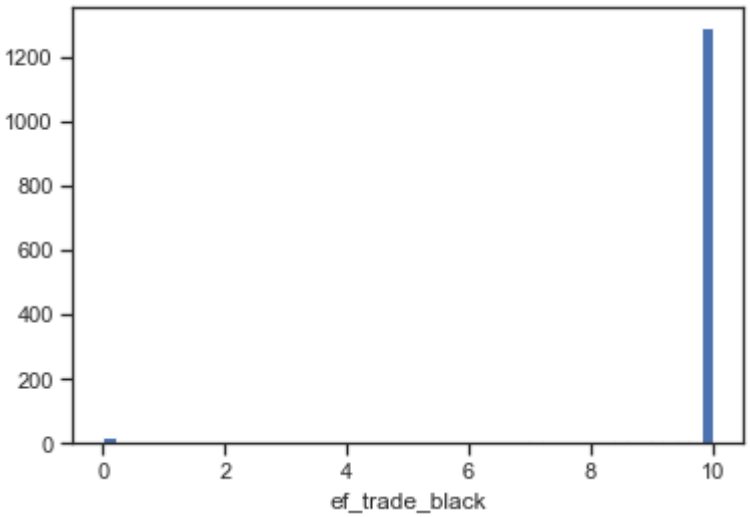
1200
1000
800
600
400
200
0
0
2
4
6
8
10
ef_trade_black

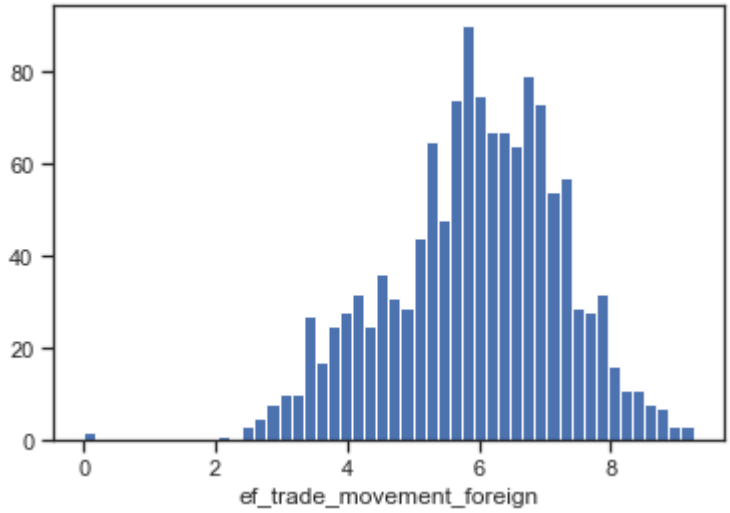
80
60
40
20
0
0
2
4
6
8
ef_trade_movement_foreign

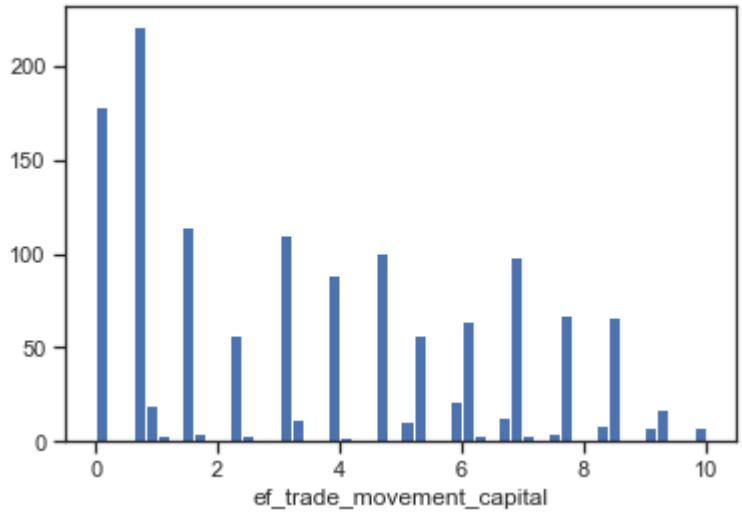
200
150
100
50
0
0
2
4
6
8
10
ef_trade_movement_capital

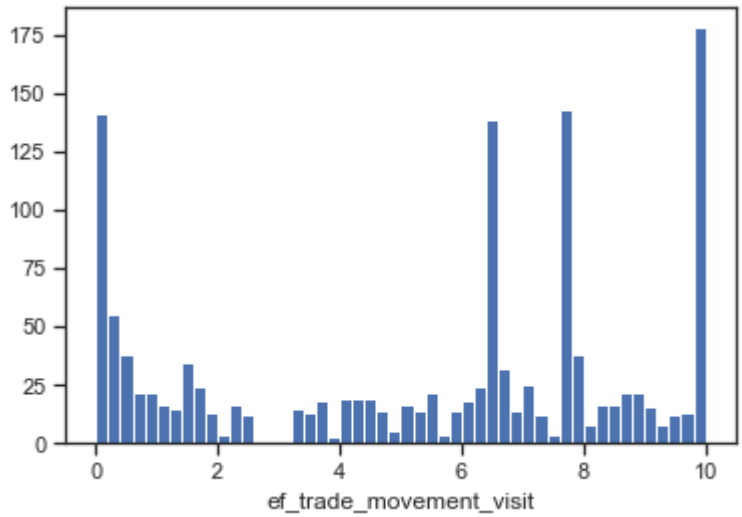
175
150
125
100
75
50
25
0
0
2
4
6
8
10
ef_trade_movement_visit

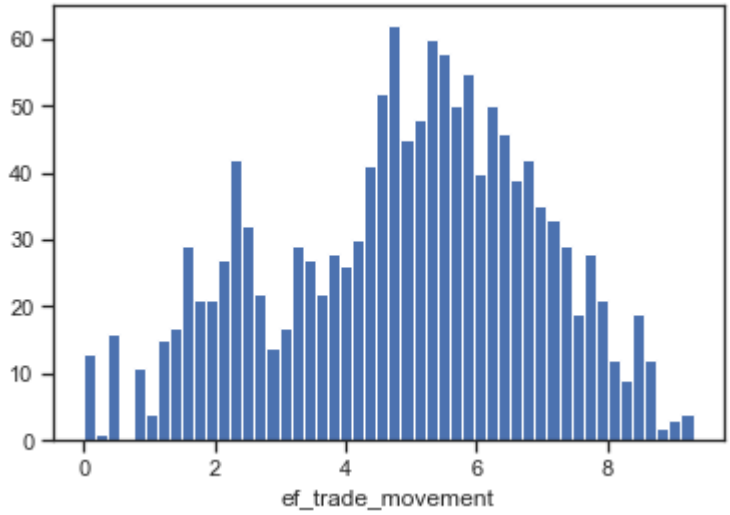
60
50
40
30
20
10
0
0
2
4
6
8
ef_trade_movement

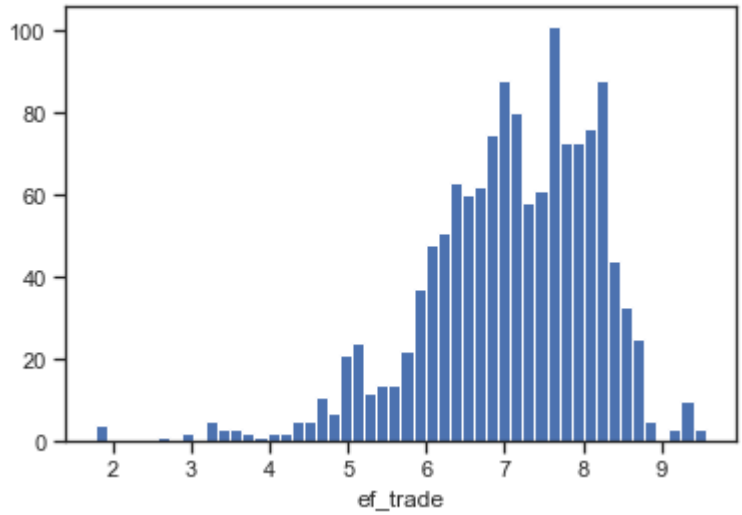
100
80
60
40
20
0
2
3
4
5
6
7
8
9
ef_trade

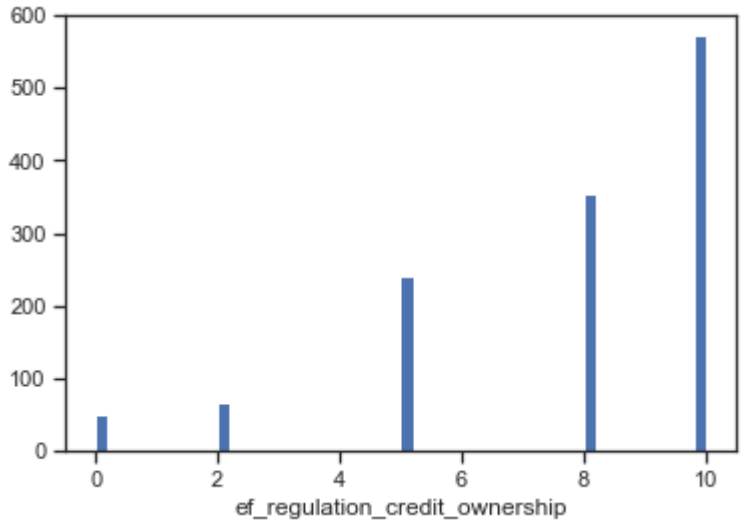
600
500
400
300
200
100
0
0
2
4
6
8
10
ef_regulation_credit_ownership

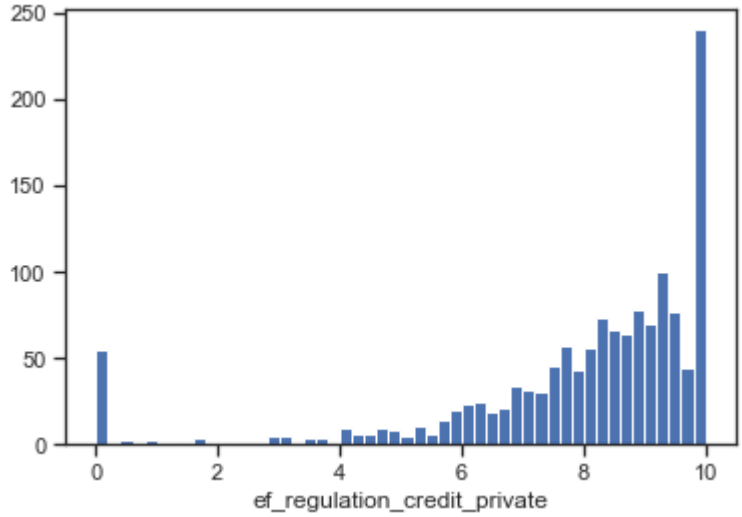
250
200
150
100
50
0
0
2
4
6
8
10
ef_regulation_credit_private

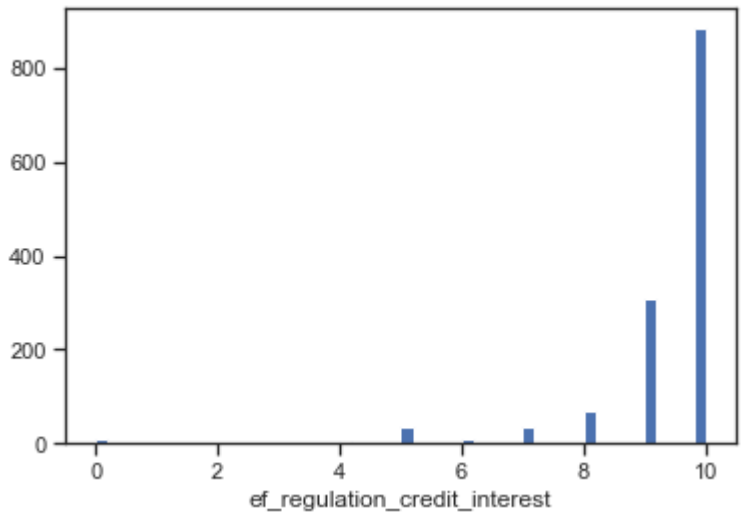
800
600
400
200
0
0
2
4
6
8
10
ef_regulation_credit_interest

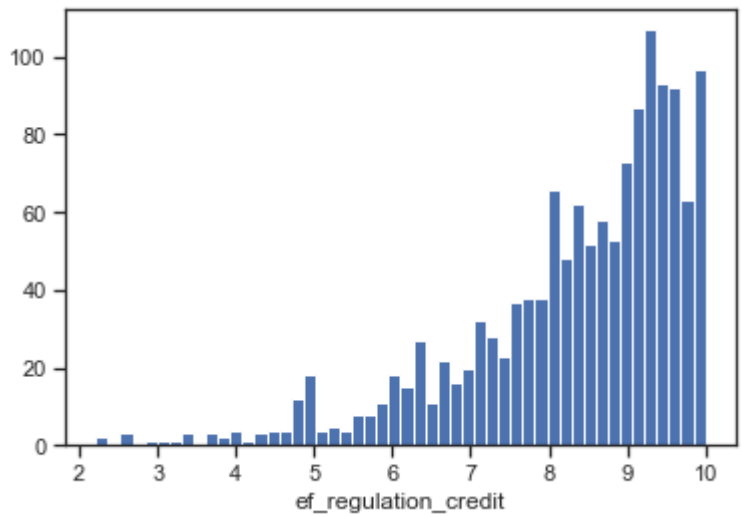
100
80
60
40
20
0
2
3
4
5
6
7
8
9
10
ef_regulation_credit

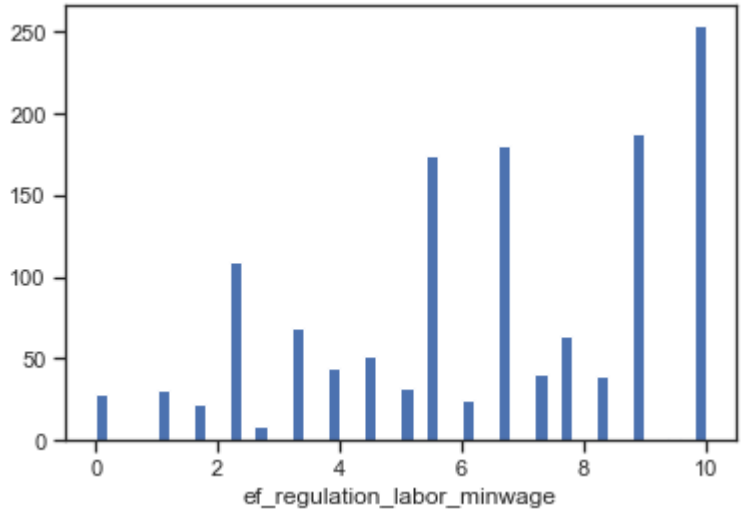
250
200
150
100
50
0
0
2
4
6
8
10
ef_regulation_labor_minwage

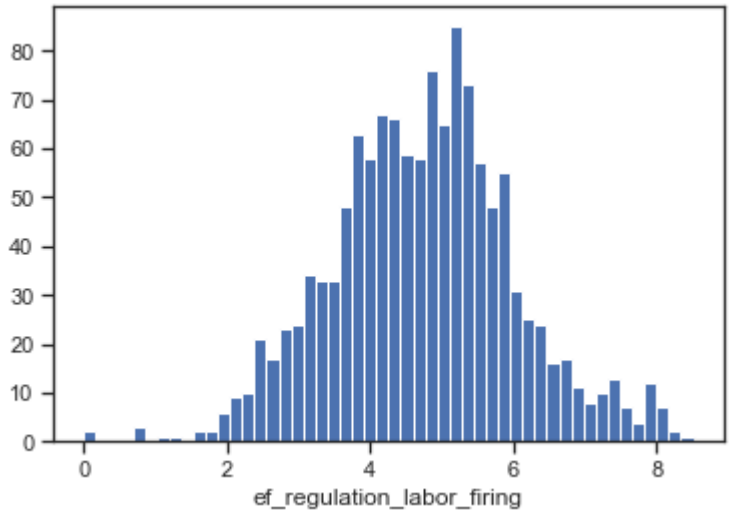
80
70
60
50
40
30
20
10
0
0
2
4
6
8
ef_regulation_labor_firing

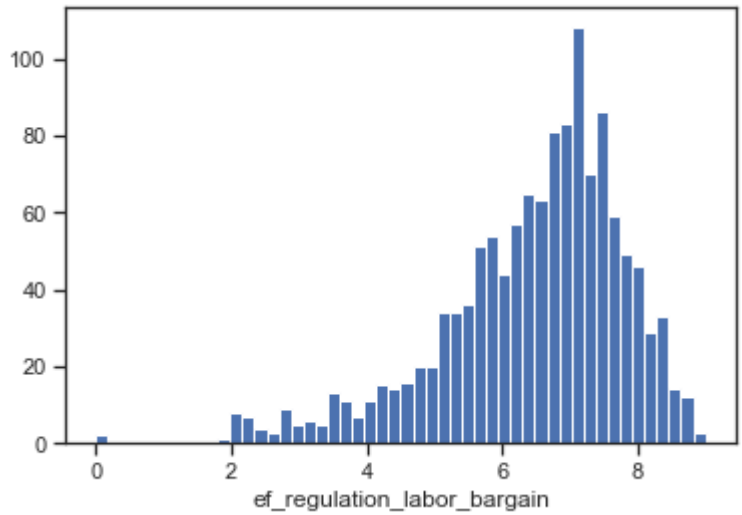
100
80
60
40
20
0
0
2
4
6
8
ef_regulation_labor_bargain

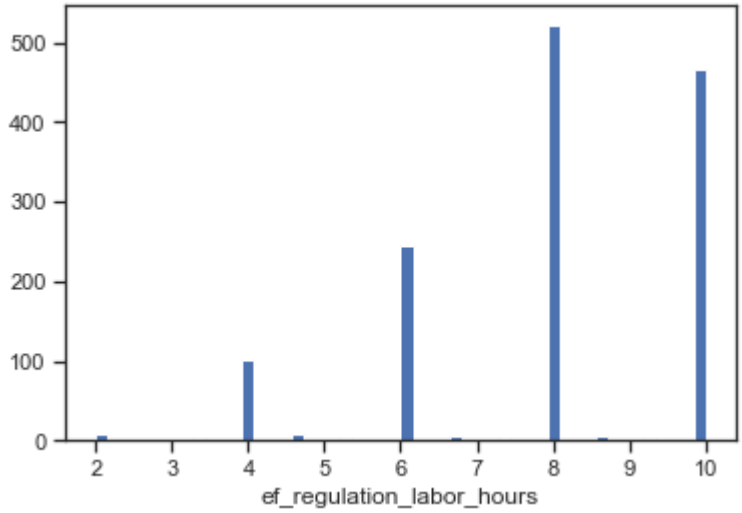
500
400
300
200
100
0
2
3
4
5
6
7
8
9
10
ef_regulation_labor_hours

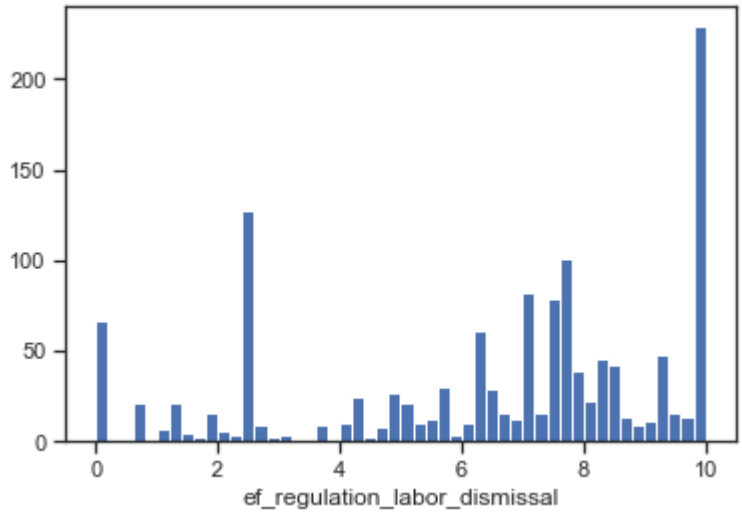
200
150
100
50
0
0
2
4
6
8
10
ef_regulation_labor_dismissal

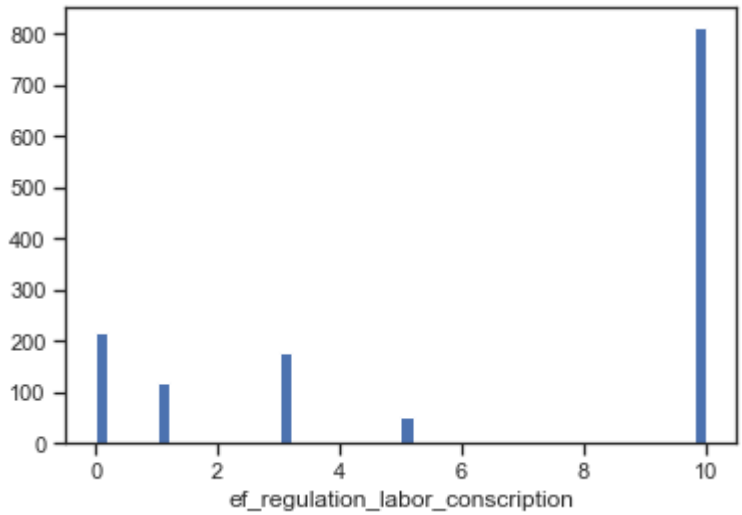
800
700
600
500
400
300
200
100
0
0
2
4
6
8
10
ef_regulation_labor_conscription

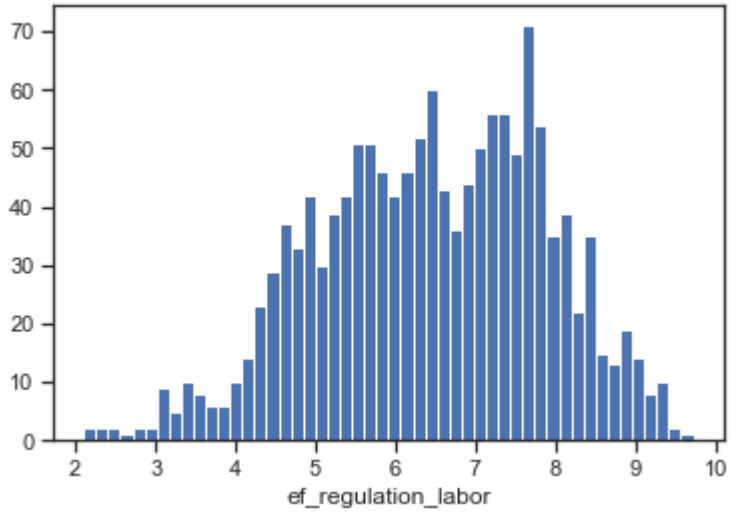
70
60
50
40
30
20
10
0
2
3
4
5
6
7
8
9
10
ef_regulation_labor

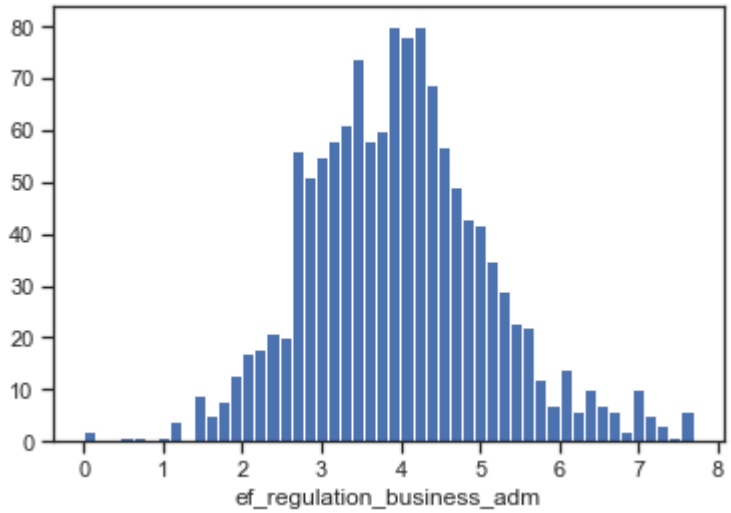
80
70
60
50
40
30
20
10
0
0
1
2
3
4
5
6
7
8
ef_regulation_business_adm

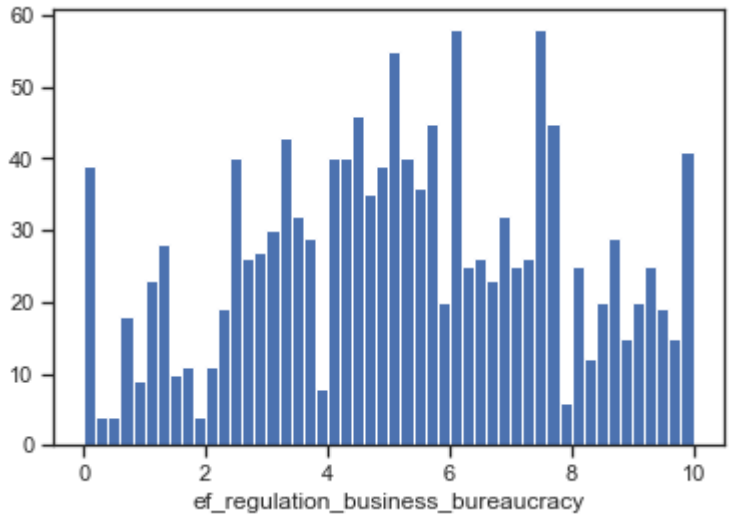
60
50
40
30
20
10
0
0
2
4
6
8
10
ef_regulation_business_bureaucracy

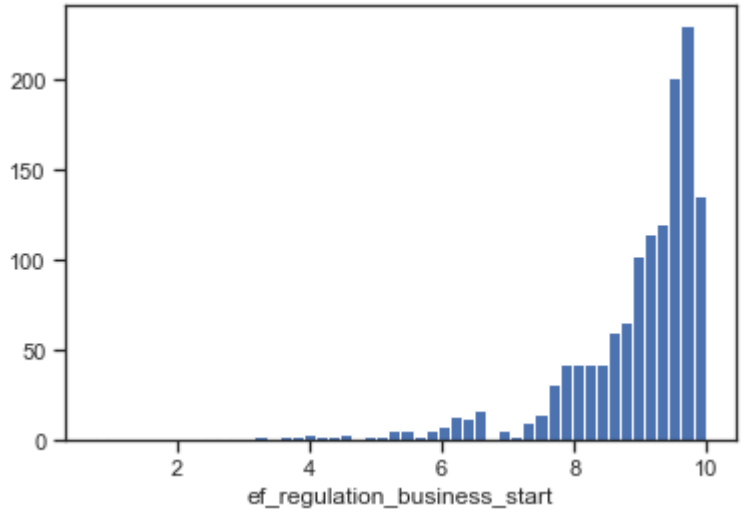
200
150
100
50
0
2
4
6
8
10
ef_regulation_business_start

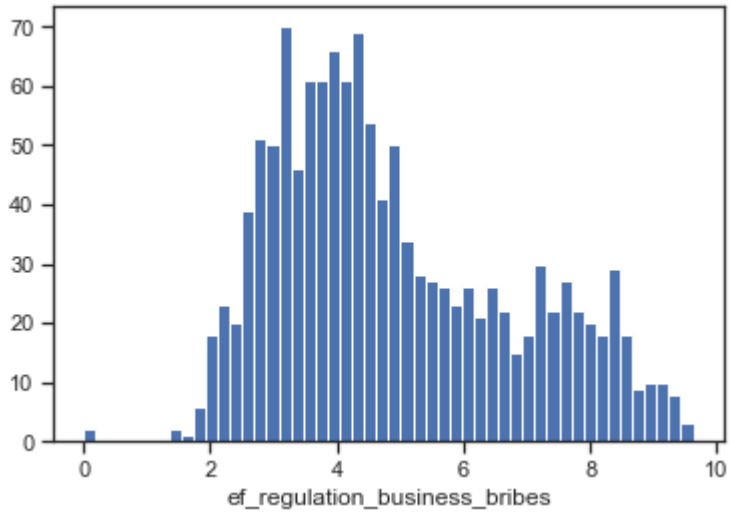
70
60
50
40
30
20
10
0
0
2
4
6
8
10
ef_regulation_business_bribes

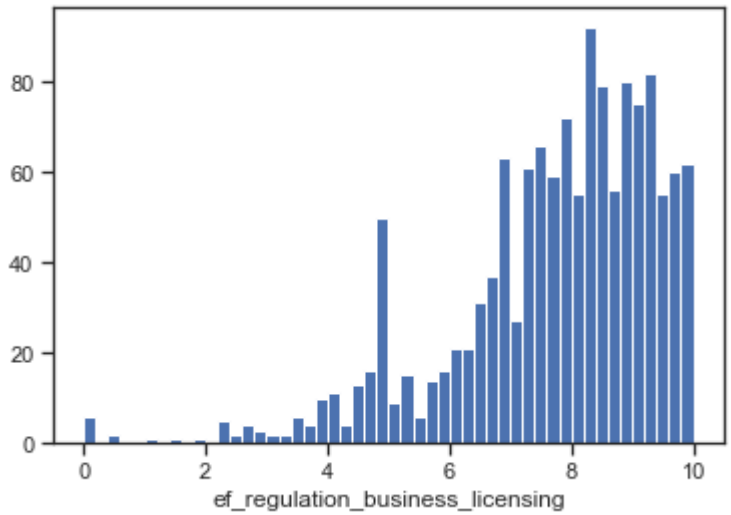
80
60
40
20
0
0
2
4
6
8
10
ef_regulation_business_licensing

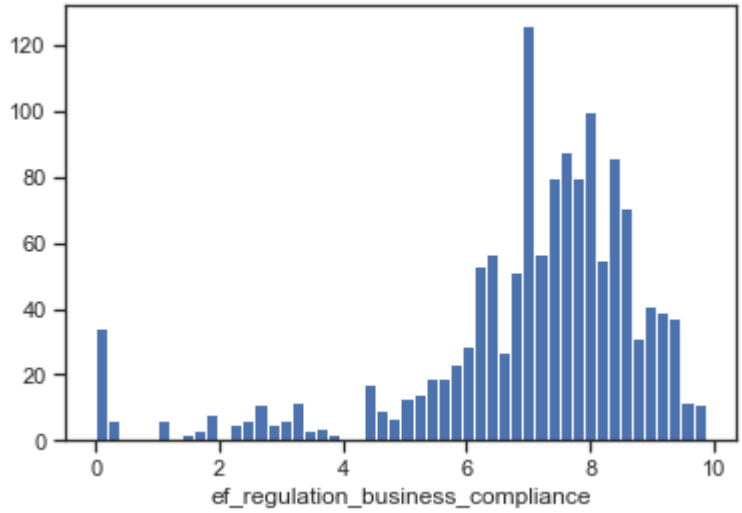
120
100
80
60
40
20
0
0
2
4
6
8
10
ef_regulation_business_compliance

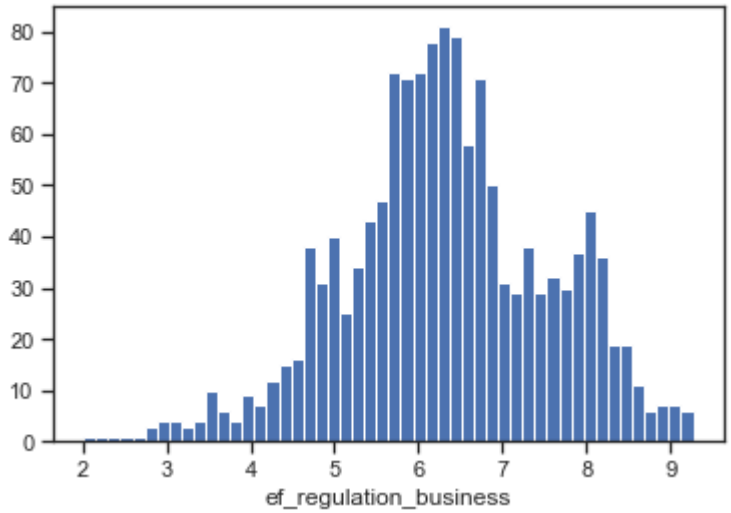
80
70
60
50
40
30
20
10
0
2
3
4
5
6
7
8
9
ef_regulation_business

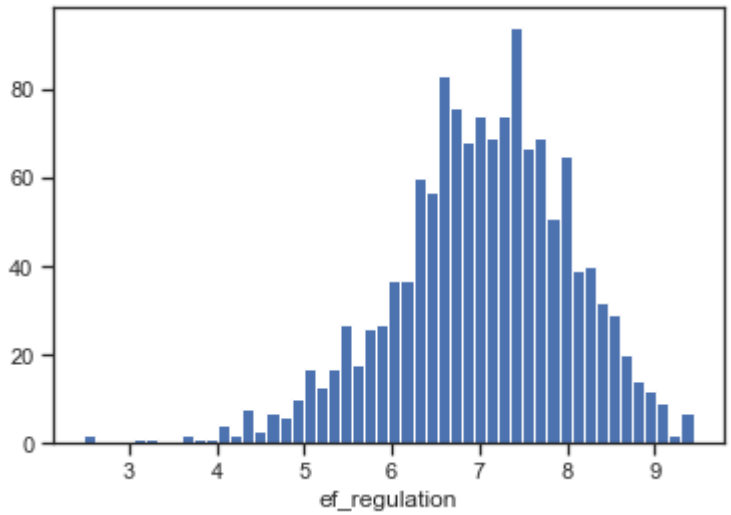
80
60
40
20
0
3
4
5
6
7
8
9
ef_regulation

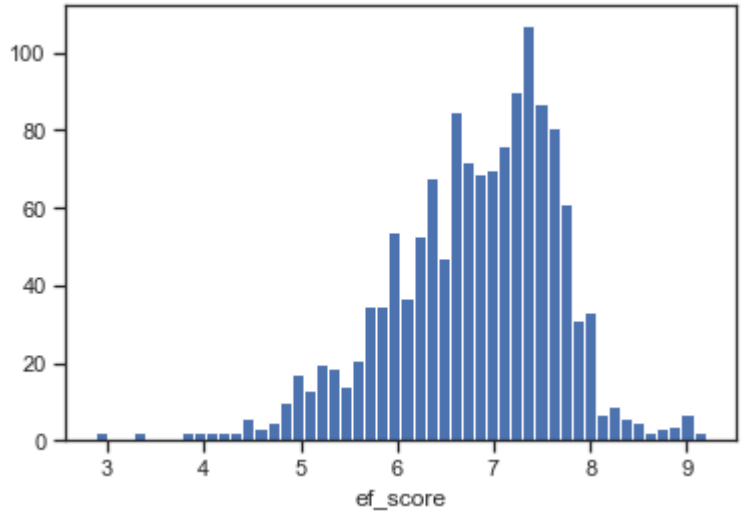
100
80
60
40
20
0
3
4
5
6
7
8
9
ef_score

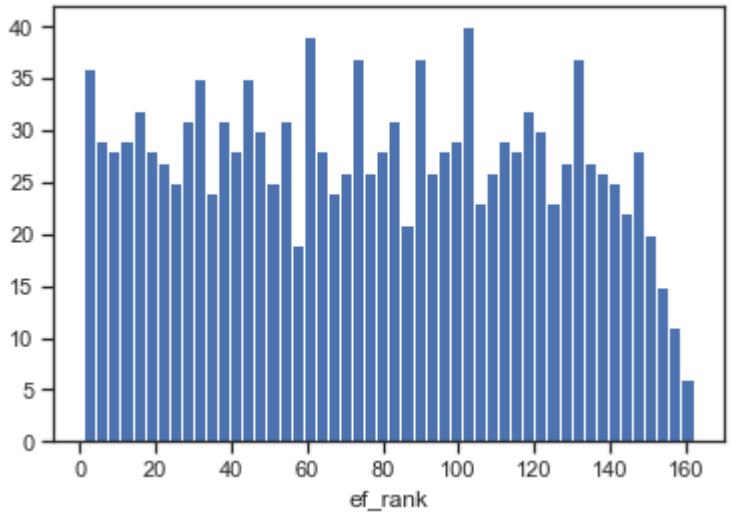
40
35
30
25
20
15
10
5
0
0
20
40
60
80
100
120
140
160
ef_rank

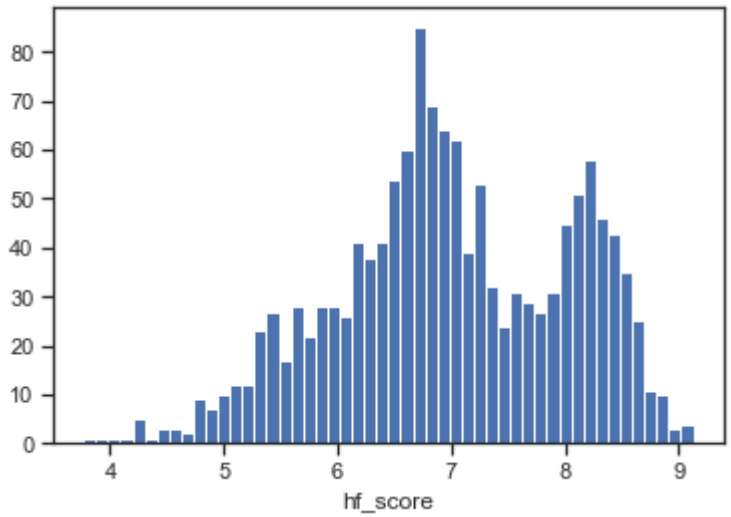
80
70
60
50
40
30
20
10
0
4
5
6
7
8
9
hf_score

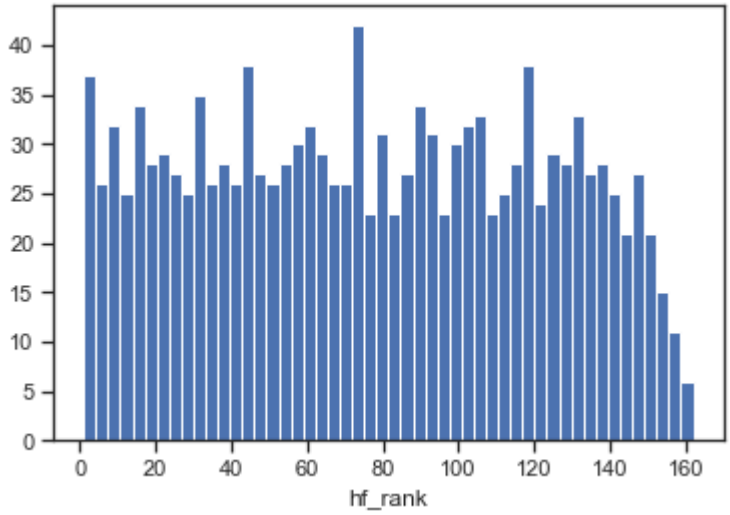

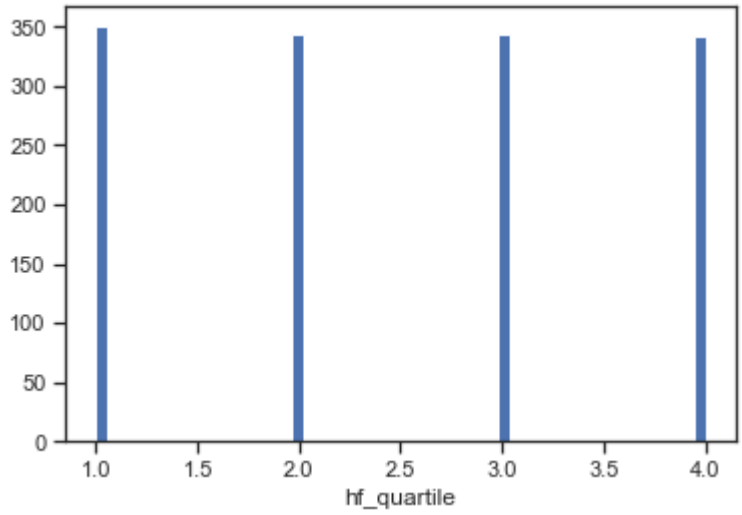

Обработка категориальных данных

In [41]:
```
# Выберем категориальные колонки с пропущенными значениями
# Цикл по колонкам датасета
cat_cols = []
for col in data.columns:
    # Количество пустых значений
    temp_null_count = data[data[col].isnull()].shape[0]
    dt = str(data[col].dtype)
    if temp_null_count>0 and (dt=='object'):
        cat_cols.append(col)
        temp_perc = round((temp_null_count / total_count) * 100.0, 2)
        print('Колонка {}. Тип данных {}. Количество пустых значений {},
if len(cat_cols) == 0:
    print("msg: Пропусков значений в категориальных данных не обнаруженно
```

```
msg: Пропусков значений в категориальных данных не обнаруженно
```

Попробуем вручную удалить некоторые данные:

In [46]:
```
# читаем данные набора
data2 = pd.read_csv('JupyterNotebooks/data/hfi_cc_2018_3.csv', sep=",")

for col in data2.columns:
    # Количество пустых значений
    temp_null_count = data2[data2[col].isnull()].shape[0]
    dt = str(data2[col].dtype)
    if temp_null_count>0 and (dt=='object'):
        cat_cols.append(col)
```

```
        temp_perc = round((temp_null_count / total_count) * 100.0, 2)
        print('Колонка {}. Тип данных {}. Количество пустых значений {},
if len(cat_cols) == 0:
    print("msg: Пропусков значений в категориальных данных не обнаруженн
```

```
Колонка ISO_code. Тип данных object. Количество пустых значений 6, 0.41%.
Колонка region. Тип данных object. Количество пустых значений 2, 0.14%.
```

Именно в этом случае можно просто удалить строки с пропушенными данными:

In [52]:
```
cat_cols_set = set(cat_cols)
cat_cols_set
```

Out[52]:
```
{'ISO_code', 'region'}
```

In [62]:
```
# Удаление строк, содержащих пустые категориальные значения
for col in cat_cols_set:
    data2_new = data2[data2[col].notna()]
(data2.shape, data2_new.shape)
```

Out[62]:
```
((1458, 123), (1452, 123))
```

В случае взятого мною набора данных такой способ более подходит: просто выбираем признаки которые в далнейшем хотим отследить, проверить зависимости и тп, и удаляем строки, у которых у этих признаков значения не установленны.

Масштабирование данных

Термины "масштабирование" и "нормализация" часто используются как синонимы. Масштабирование предполагает изменение диапазона измерения величины, а нормализация - изменение распределения этой величины.

In [63]:
```
from sklearn.preprocessing import MinMaxScaler, StandardScaler, Normaliz
```

Масштабирование МиниМакс

In [76]:
```
sc1 = MinMaxScaler()
sc1_data = sc1.fit_transform(data2[['pf_rol_criminal']])
```

In [65]:
```
plt.hist(data2['pf_rol_criminal'], 50)
plt.show()
```

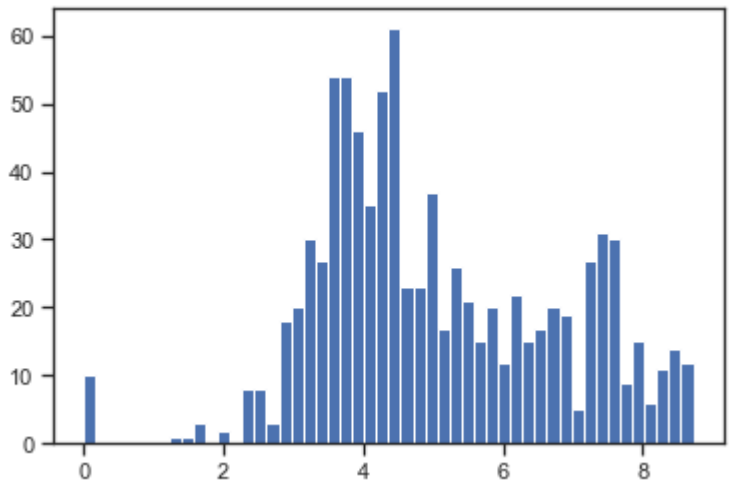

In [75]:
```
plt.hist(sc1_data, 50)
plt.show()
```

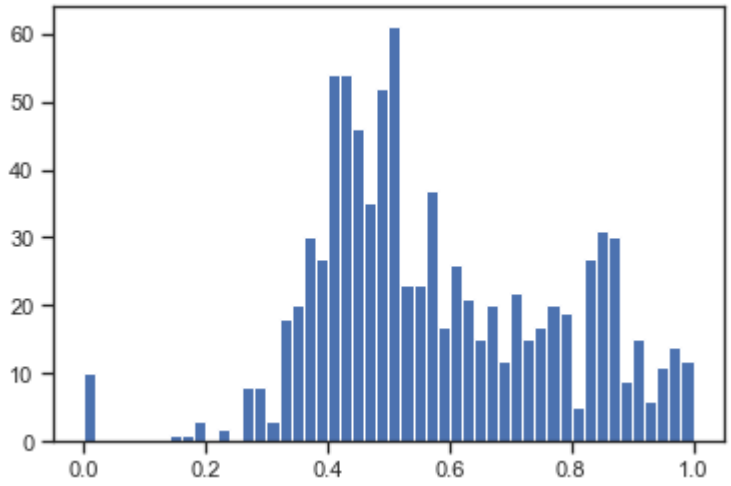

Масштабирование на основе Z-оценки

In [77]:
```
sc2 = StandardScaler()
sc2_data = sc2.fit_transform(data2[['pf_rol_criminal']])
```

In [78]:
```
plt.hist(sc2_data, 50)
plt.show()
```