Линейные модели, SVM и деревья решений.

Задание

1. Выберите набор данных (датасет) для решения задачи классификации или регрессии.
2. В случае необходимости проведите удаление или заполнение пропусков и кодирование категориальных признаков.
3. С использованием метода train_test_split разделите выборку на обучающую и тестовую.
4. Обучите следующие модели:
   - одну из линейных моделей;
   - SVM;
   - дерево решений.
5. Оцените качество моделей с помощью двух подходящих для задачи метрик. Сравните качество полученных моделей.

Выбор набора данных

Будем использовать набор данных "Диабет" для решения задачи регрессии.

In [1]:
```
import pandas as pd
import numpy as np

from sklearn.datasets import *
```

In [2]:
```
data = load_diabetes()
pd_data = pd.DataFrame(data= np.c_[data['data'], data['target']],
                       columns= data['feature_names'] + ['target'])
pd_data.head(5)
```

Out[2]:

	age	sex	bmi	bp	s1	s2	s3	s4	
0	0.038076	0.050680	0.061696	0.021872	-0.044223	-0.034821	-0.043401	-0.002592	0.
1	-0.001882	-0.044642	-0.051474	-0.026328	-0.008449	-0.019163	0.074412	-0.039493	-0.
2	0.085299	0.050680	0.044451	-0.005671	-0.045599	-0.034194	-0.032356	-0.002592	0.
3	-0.089063	-0.044642	-0.011595	-0.036656	0.012191	0.024991	-0.036038	0.034309	0.
4	0.005383	-0.044642	-0.036385	0.021872	0.003935	0.015596	0.008142	-0.002592	-0.

Подготовка набора данных к работе

In [3]:
```
pd_data.isnull().sum()
```

Out[3]:
```
age        0
sex        0
bmi        0
bp         0
```

```
s1         0
s2         0
s3         0
s4         0
s5         0
s6         0
target     0
dtype: int64
```

Набор данных не содержит пропусков. Выведем корреляционную матрицу:

In [4]:
```
import seaborn as sns

sns.heatmap(pd_data.corr())
```

Out[4]:
```
<AxesSubplot:>
```

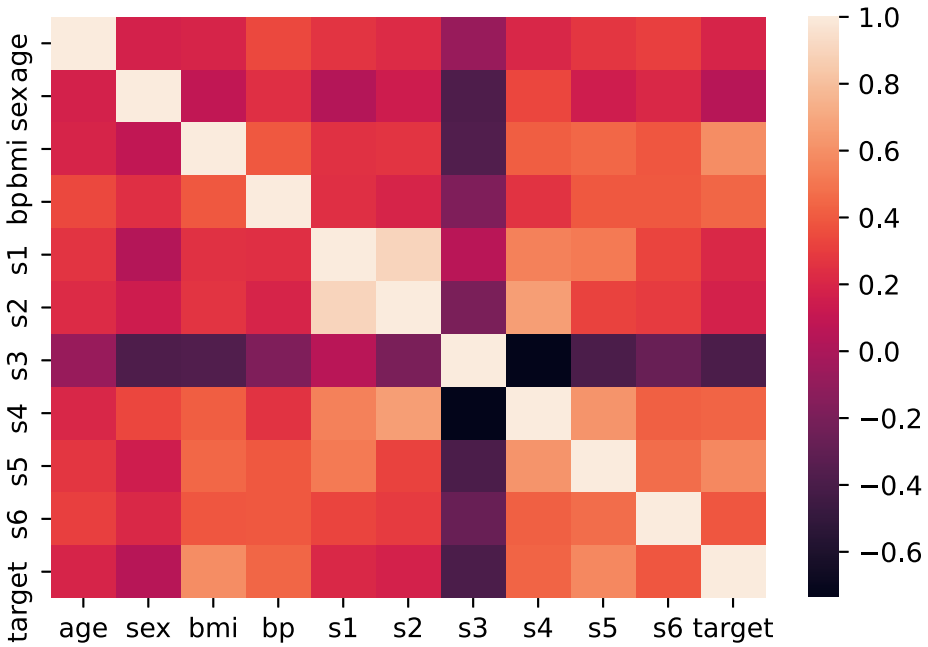

Разделим датасет на обучающую и тестовую выборки

Для этого импортируем и используем метод train_test_split

In [16]:
```
from sklearn.model_selection import train_test_split

X_train, X_test, Y_train, Y_test = train_test_split(
    pd_data['s1'].values, pd_data['s2'].values, test_size=0.5, random_st
```

Обучение моделей

Линейная модель LinearRegression

In [17]:
```
from sklearn.linear_model import LinearRegression

# Обучим модель линейной регрессии
regr1 = LinearRegression().fit(X_train.reshape(-1, 1), Y_train.reshape(-
```

Построим график:

In [18]:
```
import matplotlib.pyplot as plt

y_array_regr = [regr1.coef_[0]*x+regr1.intercept_[0] for x in X_train]

plt.plot(X_train, Y_train, 'c.')
plt.plot(X_train, y_array_regr, 'r-', linewidth=2.0)
plt.show()
```

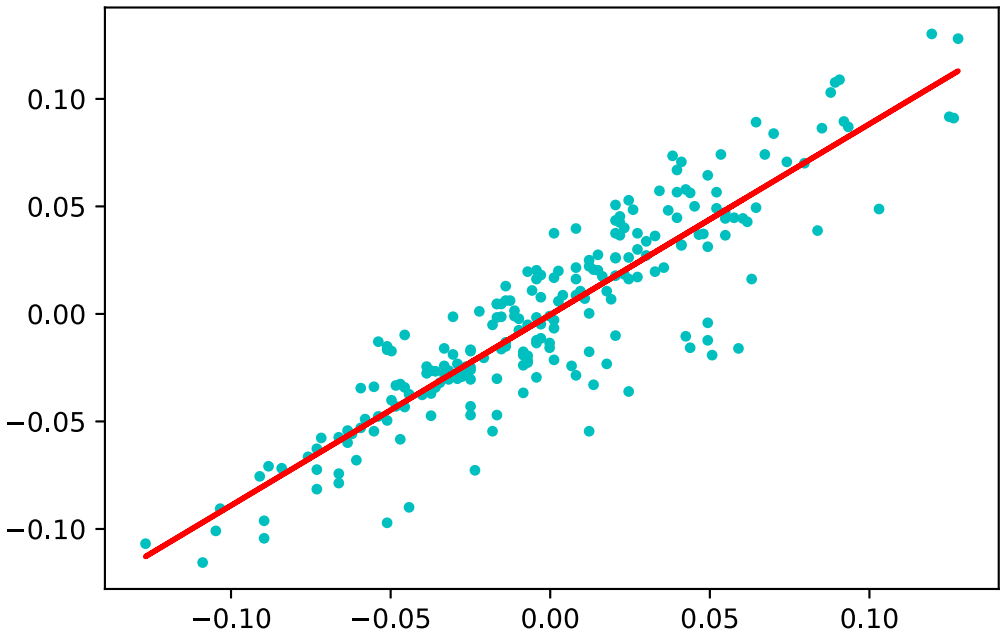

С помощью полученной модели предскажем значения для тествой выборки:

In [19]:
```
predict1 = regr1.predict(X_test.reshape(-1, 1))
```

In [20]:
```
# произведем оценку качества модели
from sklearn.metrics import median_absolute_error, r2_score

mae1 = median_absolute_error(Y_test, predict1)
r_score_1 = r2_score(Y_test, predict1)

print(f"Median abolute error: {mae1}")
print(f"R^2: {r_score_1}")
```

```
Median abolute error: 0.01264342736744006
R^2: 0.8053971815170476
```

Support vector machine (SVR)

In [35]:
```
from sklearn.svm import LinearSVR, SVR

mae2 = []
r_score_2 = []

def plot_regr(clf):
    global mae2
    global r_score_2

    title = clf.__repr__
    clf.fit(X_train.reshape(-1, 1), Y_train)
    predict2 = clf.predict(X_test.reshape(-1, 1))

    mae2.append(median_absolute_error(Y_test, predict2))
    r_score_2.append(r2_score(Y_test, predict2))
```

```
    print(f"Median abolute error: {mae2[-1]}")
    print(f"R^2: {r_score_2[-1]}")

    fig, ax = plt.subplots(figsize=(5,5))
    ax.set_title(title)
    ax.plot(X_test, Y_test, 'c.')
    ax.plot(X_test, predict2, 'r.')
    plt.show()

plot_regr(LinearSVR(C=1.0, max_iter=10000))
```

```
Median abolute error: 0.012122870938388097
R^2: 0.8043279051239223
```

<bound method BaseEstimator.__repr__ of LinearSVR(max_iter=10000)>

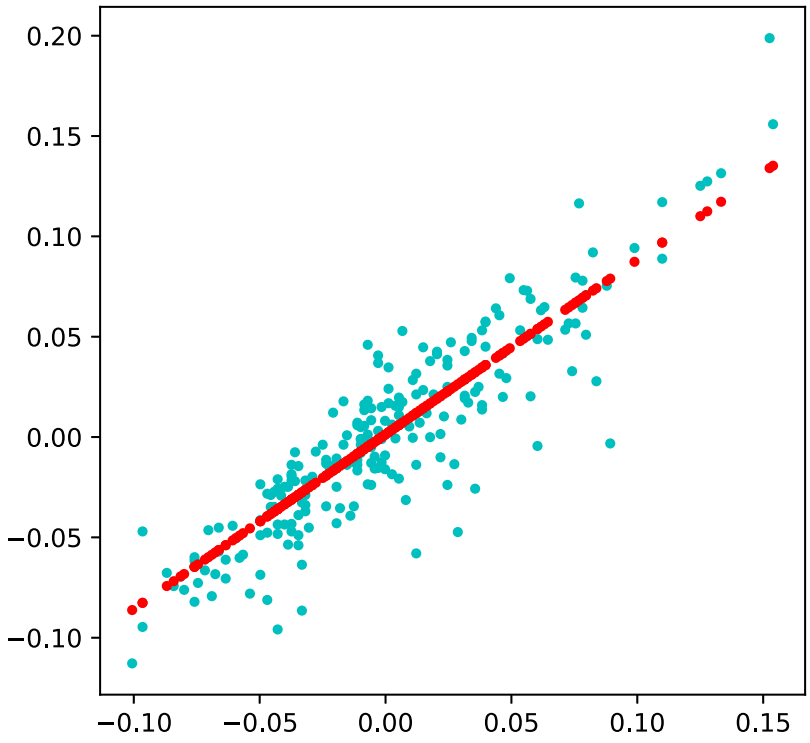

In [36]:
```
plot_regr(SVR(kernel='linear', C=1.0))
```

```
Median abolute error: 0.02729380424847858
R^2: 0.3045447711612119
```

<bound method BaseEstimator.__repr__ of SVR(kernel='linear')>

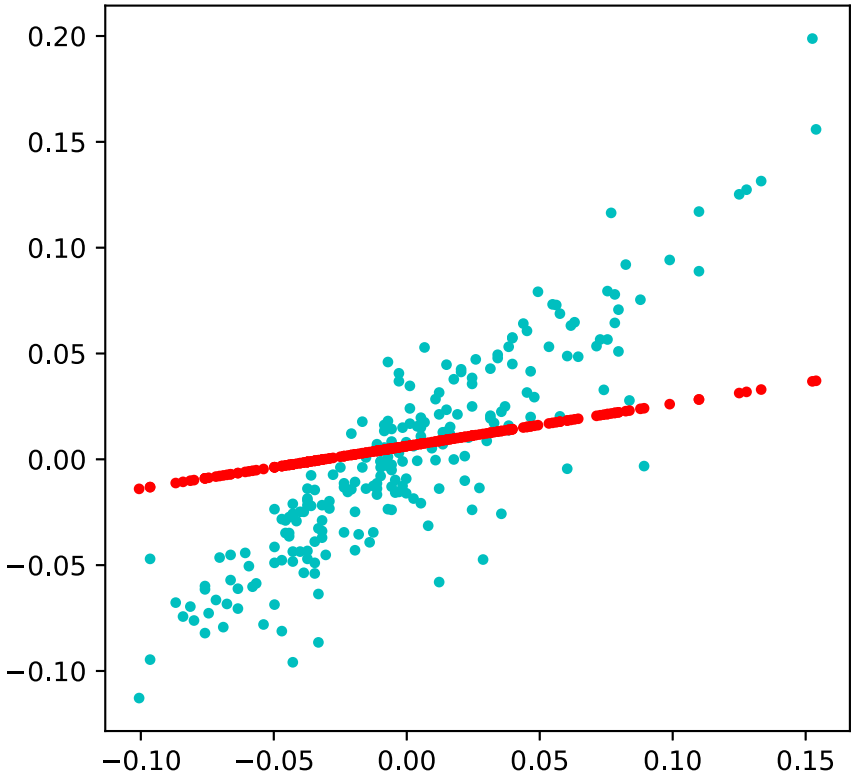

In [37]:
```
plot_regr(SVR(kernel='rbf', gamma=0.99, C=1.0))
```

```
Median abolute error: 0.027245444459994397
R^2: 0.3059804373028481
```

<bound method BaseEstimator.__repr__ of SVR(gamma=0.99)>

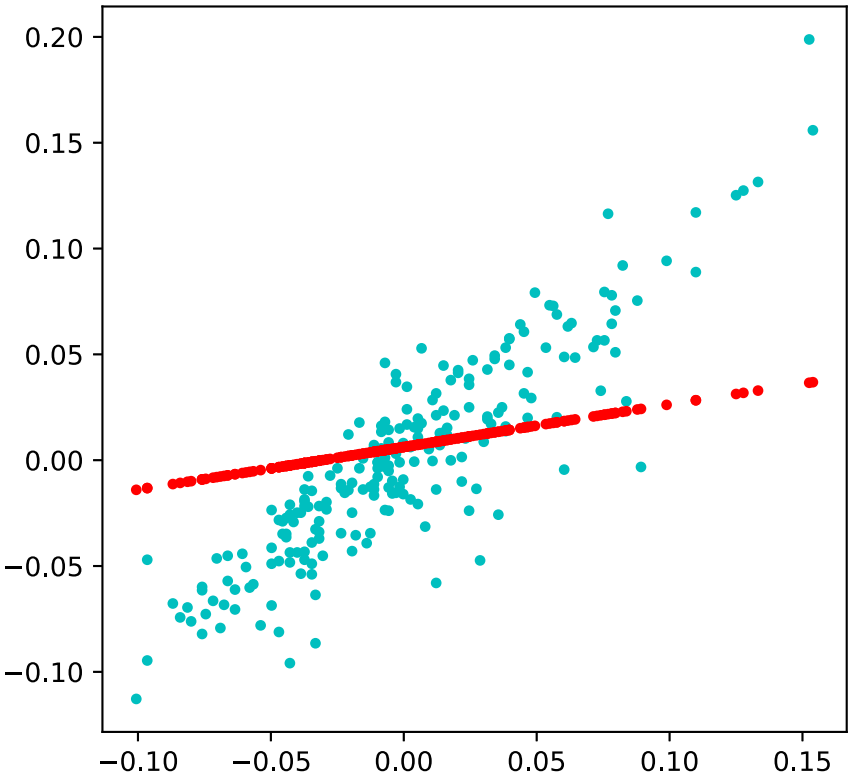

Дерево решений

In [32]:
```
from sklearn.tree import DecisionTreeRegressor
from sklearn.model_selection import GridSearchCV
```

```
n_range = np.array(range(1, 12, 1))
tuned_parameters = [{'max_depth': n_range}]

regr3 = GridSearchCV(DecisionTreeRegressor(), tuned_parameters, cv=5, sc
regr3.fit(X_train.reshape(-1, 1), Y_train.reshape(-1, 1))
predict3 = regr3.predict(X_test.reshape(-1, 1))

print("Наиболее подходящая глубина дерева: {0}".format(regr3.best_params_
print("Значение метрики: {0}".format(regr3.best_score_))
```

```
Наиболее подходящая глубина дерева: {'max_depth': 4}
Значение метрики: 0.7533199836095925
```

К сожалению никак не могу докачать модуль graphviz в виртуальное окружение анаконды, поэтому построить графически дерево не получается.

In [33]:
```
# произведем оценку качества модели
mae3 = median_absolute_error(Y_test, predict3)
r_score_3 = r2_score(Y_test, predict3)

print(f"Median abolute error: {mae3}")
print(f"R^2: {r_score_3}")
```

```
Median abolute error: 0.014040899948887388
R^2: 0.7771737901066518
```

Вывод

In [39]:
```
print(f"Linear regression Median abolute error: {mae1}")
print(f"Linear regression R^2 score: {r_score_1}\n")

counter = 1
for r in mae2:
    print(f"SVM Median abolute error {counter}: {r}")
    counter += 1
counter = 1
for r in r_score_2:
    print(f"SVM R^2 score {counter}: \033[32m{r_score_1}\033[0m")
    counter += 1

print(f"\nSolution Tree Median abolute error: {mae3}")
print(f"Solution Tree R^2 score: {r_score_3}\n")
```

```
Linear regression Median abolute error: 0.01264342736744006
Linear regression R^2 score: 0.8053971815170476

SVM Median abolute error 1: 0.012122870938388097
SVM Median abolute error 2: 0.02729380424847858
SVM Median abolute error 3: 0.027245444459994397
SVM R^2 score 1: 0.8053971815170476
SVM R^2 score 2: 0.8053971815170476
SVM R^2 score 3: 0.8053971815170476

Solution Tree Median abolute error: 0.014040899948887388
Solution Tree R^2 score: 0.7771737901066518
```

Наилучший результат оценки получила модель Дерева решений, но при этом оценки остальных моделей отличаются всего на несколько "сотых"